

orchestrator/ 代码说明

给第一次看这份代码的人快速建立地图用的开发文档。`main.py` 只是薄薄的入口胶水代码，真正的 5 个 Agent 各自一个文件放在 `agents/` 目录下，`persona / store / trip_plan` 三个模块已经被对应的 Agent 接起来了（具体接了什么见文末），只有 OTA/酒店 Agent 还是纯占位假数据。

设计背景/接口契约见 [agent-architecture.md](#)（为什么这么分 Agent、为什么中心化编排）和 [agent-interfaces.md](#)（字段契约、原本的 Dify 方案，后来改成直接写 Python）。

环境准备

```
pip install openai python-dotenv chromadb
```

在 `orchestrator/.env` 里写这几行（这个文件已经在 `.gitignore` 里，不会被提交）：

```
PARATERA_API_KEY=你的key
AMAP_KEY=你的高德Web服务API Key
AMAP_JS_KEY=你的高德Web端(JS API)Key
AMAP_JS_SECURITY_CODE=你的安全密钥
```

高德的 key **分三样东西，缺一个都不行**： - `AMAP_KEY`： **Web服务** 类型，后端用（`map_tool.py` 查地理编码/路线） - `AMAP_JS_KEY`： **Web端(JS API)** 类型，前端画地图用——注意这是另一个应用/另一个 key，不能跟上面那个通用 - `AMAP_JS_SECURITY_CODE`： 安全密钥，高德 JS API 2.0 版本强制要求，在申请 `AMAP_JS_KEY` 的同一个应用页面能找到

都在 <https://lbs.amap.com> 控制台“创建应用”里申请（一个应用可以同时创建 Web服务 + Web端(JS API) 两个 key，安全密钥在创建 Web端(JS API) key 的时候会一起给）。个人开发者未认证 6000次/天，实名认证后 30万次/月，demo 阶段够用。

每个文件都能直接 `python orchestrator/<路径>.py` 单独跑（包括 `agents/` 里的 5 个文件），文件末尾的 `if __name__ == "__main__":` 都是自测代码，可以照着抄用法。

目录结构

```
orchestrator/
  llm_tool.py          # 通用 LLM 调用工具，跟"编排"本身无关，谁都能 import
  map_tool.py          # 通用地图工具（高德地图 API）：地理编码 + 路径规划
  agents/
    orchestrator_agent.py  # 编排 Agent: new_shared_state + classify_intent + orchestrate
    content_agent.py       # 达人/内容 Agent
    route_agent.py         # 行程/路线 Agent
    ota_hotel_agent.py     # OTA/酒店 Agent（还是纯占位）
    exception_agent.py    # 异常应变 Agent
  widgets.py            # 展示插件：右侧聊天框里的富交互小组件，跟 Agent 逻辑解耦
  schedule_widgets.py    # 左侧日程面板展示组件（地图+连线、每日时间线、机票酒店面板），跟 widgets.
  standardize_hk_macau_data.py # 把组员整理的港澳达人数据 Excel 转成标准化 JSON（见文末专门一节）
  import_hk_macau_data.py # 把标准化 JSON 灌进 Chroma（人格向量怎么算在这一步）
  data_sources/hk_macau_posts.json # 标准化后的港澳达人数据库（229 条，本地人认证 + 小红书两个来源）
  main.py               # 薄入口：re-export 编排 Agent 的两个函数 + __main__ 完整 demo
  store.py / trip_plan.py / persona.py # 不变
  server.py / web/      # 不变，还是 import main，接口不受这次拆分影响
```

拆分原则：谁负责哪个 Agent 就改 agents/ 下自己那一个文件，不用碰 main.py 或别人的 Agent 文件，减少多人协作冲突。

llm_tool.py -- 通用 LLM 工具

职责：跟"编排"这件事本身无关的基础设施，5 个 Agent 里任何一个要调用模型都用这个，不要各自再写一遍 client 初始化。

函数/常量	作用
call_llm(messages, model=MODEL_FULL)	统一的模型调用入口
MODEL_FULL / MODEL_LIGHT	DeepSeek-V4-Pro / DeepSeek-V4-Flash，两档模型对齐 agent-architecture.md 的模型档位设计

map_tool.py -- 通用地图工具（高德地图）

职责：地理编码 + 路径规划，给行程/路线 Agent 算真实的距离/耗时/路线用，跟 llm_tool.py 一样是通用基础设施。

函数	作用
geocode(address, city=None)	地名/地址转经纬度，返回 (lng, lat)

函数	作用
<code>route_between(place_a, place_b, mode="walking", city=None)</code>	算两地之间的距离/耗时/路线, <code>mode</code> 传 "walking" 或 "driving", 返回 <code>distance_m / duration_min / polyline</code>

现状/限制: - 只做了"两点之间"的查询, 还没做"多点一次性规划最优顺序" (这个高德也有专门接口, 以后要优化路线顺序时再接) - `route_agent.py` 里用这个算相邻两站的真实交通方式/耗时 (超过 2km 自动从步行切驾车), 查询失败会优雅降级成"待定 (地图查询失败: ...) "文字, 不会导致整个流程崩掉 - 到达/结束的具体钟点时间 (`arrival_time / end_time`) 还是占位——那需要"一天几点开始"+"每站玩多久"这类还没定义的调度逻辑, 跟地图 API 是两回事 - 地图可视化 (真的在网页上画一张地图+路线) 还没做, `web/index.html` 目前只是文字列表展示行程, `polyline` 字段目前没被前端用上

agents/orchestrator_agent.py -- 编排 Agent

职责: 星型架构的中枢。接收用户消息 → 意图识别 → 决定调用哪几个子 Agent → 汇总结果 → 生成回复。对应 [agent-interfaces.md 第三节](#) 的节点拓扑, 只是从 Dify 可视化节点换成了 Python 函数。模型档位用 `MODEL_FULL` (全系统推理最重)。

函数	作用
<code>new_shared_state(user_id, scenario="vacation", onboarding_answers=None)</code>	造一份共享状态: <code>persona</code> (真用 <code>persona.py</code> 的结构, 传了 <code>onboarding_answers</code> 就走冷启动) + <code>trip_plan</code> (真用 <code>trip_plan.py</code> 的结构)
<code>classify_intent(user_message)</code>	调模型判断这轮要触发 <code>content / route / booking / exception</code> 里的哪几个
<code>orchestrate(user_message, shared_state)</code>	主流程: 意图识别 → 分发调用 4 个子 Agent (子 Agent 直接改 <code>shared_state</code> 里的 <code>trip_plan</code> , 不用再手动写回) → 生成回复, 返回 (<code>output, shared_state</code>)

`orchestrate()` 返回的 `output` 里除了 `chat_reply / community_panel / map_panel`, 还有一个 `widgets` 数组 (见下面 `widgets.py` 一节): `content` 意图命中时会调 `widgets.build_post_list_widget()` + `widgets.build_attraction_picker_widget()`, 命中候选为空就是空数组。

agents/content_agent.py -- 达人/内容 Agent

职责: 两阶段检索第一阶段。模型档位 `MODEL_FULL` (UGC 语义提炼), 目前还没实际调用 LLM (纯向量检索)。

`run(shared_state, location_hint, top_k=3)`: 算 `persona` 向量 → `store.query_similar_posts()` 查候选。
`location_hint` 现在有两个用途: (1) `_extract_city()` 从消息原文里子串匹配"澳门"/"香港" (词表

`_KNOWN_CITIES`) , 匹配上了就把 `city` 传给 `query_similar_posts()` 做硬过滤, 不然"查香港"会混进澳门结果——纯人格相似度检索不区分城市, 得靠这个过滤兜底; (2) 留给"内容相关性排序" (两阶段检索第二阶段) 用, 那部分还没实现。匹配不到已知城市 (比如老的杭州 demo 数据、或者压根没提城市) 就不过滤, 跟以前行为一样。跟 `exception_agent.py` 的子串匹配是同一个"先跑起来, 以后再换实体识别"的思路。

返回的 `recommendations` 每条现在除了原有字段, 还带港澳数据库的字段:

`city / category / post_type / address / tags / verified_local` (杭州那批老 demo 数据没有这些, 会是 `None` / 空列表 / `False` , 不影响原有字段读取) 。

agents/route_agent.py -- 行程/路线 Agent

职责: 把地点写进 `trip_plan` 某一天的行程节点。模型档位 `MODEL_LIGHT` , 目前还没接 LLM, 纯结构化写入。

`run(shared_state, places, time_budget=None, city=None)` : 所有节点目前都写进同一个占位日期 (`_PLACEHOLDER_DAY = "day-1"`) 。 `arrival_transport` 已经接了 `map_tool.py` , 是相邻两站之间真实算出来的交通方式/耗时/距离 (超过 2km 自动从步行切驾车) ; `arrival_time / end_time` 还是占位文字 "待定" (原因见 `map_tool.py` 那节) 。

agents/ota_hotel_agent.py -- OTA/酒店 Agent

职责: 查库存/比价。模型档位 `MODEL_LIGHT` 。 **还是纯占位假数据**, 没有真实的比价/查库存来源可接——但字段已经补全到"用户选中后能直接落地"的程度: 机票候选带 `flight_no / from_ / to / depart_time / arrive_time / status` , 酒店候选带 `address / check_in / check_out` (`check_in / check_out` 会用 `date_range` 参数填, 格式 "开始日期~结束日期", 没传就给占位日期) 。这样 `POST /widget-response` (见 `server.py` 一节) 收到用户选中的候选后, 能直接拿这些字段调 `trip_plan.add_flight() / add_hotel()` , 不用现造字段。

`orchestrate()` 里 `booking` 意图命中时会把这里返回的 `candidates` 分别喂给 `widgets.build_flight_picker_widget() / widgets.build_hotel_picker_widget()` (按 `candidates` 里的 `provider_type` 字段分流, 见下面 `widgets.py` 一节) , 现在假数据一条机票一条酒店都有, 两个 widget 都能出内容。

agents/exception_agent.py -- 异常应变 Agent

职责: 按地点名字匹配 `trip_plan` 里的行程节点, 命中就删掉并记一条天气异常。模型档位架构文档里写的是"中等模型", 目前只有 `MODEL_FULL / MODEL_LIGHT` 两档, 先待定。

`run(shared_state, event_type, event_detail=None)` : `event_detail` 目前是纯子串匹配 (整句用户消息去匹配地点名字) , 很粗糙, 真实版本应该先做实体识别。

widgets.py -- 展示插件（右侧聊天框富交互组件）

职责： 右侧聊天框里除了纯文字回复之外的富交互小组件（帖子列表、景点勾选等），跟 Agent/编排逻辑解耦——组件只负责"从真实候选集里挑/怎么展示"，不重新跑检索或编内容。

设计原则： - 候选集永远来自真实代码算出来的数据（目前是 `content_agent.run()` 的 `recommendations`，已经是 `store.query_similar_posts()` 按人格相似度排过序的真实结果），不允许凭空捏造。 - 要用 LLM 做"选择/排序"时，LLM 只能从候选集里选 ID，不允许自己编内容；`_llm_select()` 会校验 LLM 返回的 ID 是否都在候选集里，筛掉任何编造的 ID（防幻觉），LLM 调用/解析失败时优雅降级成"按候选集原有顺序截取前 N 个"，不影响整体流程。 - 每个 widget 统一格式 `{"widget": "<type>", "data": {...}}`，前端按 widget 类型分发渲染，渲染逻辑完全不用管数据是怎么算出来的。 - 模型档位：`_llm_select()` 内部用 `llm_tool.MODEL_LIGHT`（选择/排序是结构化任务，不需要强模型）。

函数	作用
<code>build_post_list_widget(candidates, top_k=3, use_llm_rerank=False)</code>	帖子展示插件：默认直接截取候选集前 <code>top_k</code> 个（候选集已经是真实排序过的，不用额外调 LLM）；传 <code>use_llm_rerank=True</code> 走 LLM 二次筛选
<code>build_attraction_picker_widget(candidates, max_select=3, pool_size=6, use_llm_rerank=True)</code>	景点选择插件：从候选里选出 <code>pool_size</code> 个放进"可选池"返回给前端，用户从池子里最多勾 <code>max_select</code> 个；默认走 LLM 精选候选池（LLM 只能选真实 ID）
<code>build_flight_picker_widget(candidates, max_select=1, pool_size=3, use_llm_rerank=True)</code>	机票选择插件：跟 <code>build_attraction_picker_widget</code> 同一套"可选池 + 前端勾选 + 结果回传"契约，只是机票通常只订一个，默认 <code>max_select=1</code> ；从 <code>candidates</code> 里只挑 <code>provider_type == "flight"</code> 的，走 LLM 精选出 <code>pool_size</code> 个放进候选池；筛出来是空的就返回 <code>None</code> （调用方按 <code>None</code> 跳过，不展示空插件）
<code>build_hotel_picker_widget(candidates, max_select=1, pool_size=3, use_llm_rerank=True)</code>	酒店选择插件：跟 <code>build_flight_picker_widget</code> 同一个模式，只挑 <code>provider_type == "hotel"</code> 的；同样可能返回 <code>None</code>

依赖： - `content_agent.py` 返回的 `recommendations` 每条都带 `post_id` 字段（`store.query_similar_posts()` 本来就返回这个字段，之前 `content_agent.py` 组装返回值时漏传了，现已补上），
`build_post_list_widget` / `build_attraction_picker_widget` 靠这个字段做 ID 校验。 -
`build_flight_picker_widget` / `build_hotel_picker_widget` 的候选（`ota_hotel_agent.run()` 的 `candidates`）没有独立 id 字段，改用 `name` 字段当 `_llm_select` 的校验 key——跟 `post_id` 是同样的作用，只是换了个字段名。

四个 widget 分两种交互模式： `post_list` 是纯展示（截取直接列出来）；
`attraction_picker` / `flight_picker` / `hotel_picker` 是"可选池 + 前端勾选 + 结果回传"——`options` + `max_select` 是统一契约，机票/酒店默认 `max_select=1`（通常只订一个），景点默认 `max_select=3`（可以多选几个）。

现状：四个 widget 都已经真正接进 `web/index.html` 渲染，`POST /widget-response` 接口也做完了（见 `server.py` 一节）——右侧聊天框里能看到真实的卡片/勾选交互，勾完点"确认选择"会真的把机票/酒店写进 `trip_plan`、把景点排进路线，不再是"传了但没人用"的状态。

待接事项：- 讨论过的其他 widget 想法还没做：反馈评分插件、异常变更确认插件、人格问卷引导插件

schedule_widgets.py -- 左侧日程面板展示组件

职责：服务对象是左侧实时日程面板（`server.py` 的 `GET /trip`，`web/index.html` 目前的文字列表），跟右侧聊天框的 `widgets.py` 是同一个"数据/展示分离"思路——这里只算"给前端画图/排版用的数据"，不产出任何 HTML/画布逻辑，真正怎么画留给前端。模型档位：不需要 LLM，纯确定性计算（按天/类型分配颜色 + 查真实地理数据）。三个 widget：

函数	作用
<code>build_trip_map_widget(trip_plan_obj, city=None)</code>	地图组件：把每天的景点/餐饮节点标进地图（同一天同一个颜色，颜色按"第几天"从固定调色板分配，超过 8 天循环复用），并把当天节点依次连成一条 真实路线 （查真实路况，不是直线连线，颜色跟当天 markers 一致）；机票起降机场、酒店地址也各标一个点，用固定颜色（不参与按天上色，因为它们不属于"某一天"）。多城市行程会按地理距离自动 分帧 （见下），不再是所有点挤在同一张地图里
<code>build_day_timeline_widget(trip_plan_obj)</code>	每日行程时间线：把每天的节点按时间顺序整理成竖排列表，按天分模块，模块颜色跟 <code>build_trip_map_widget</code> 里同一天的颜色对齐，方便地图和列表对照着看
<code>build_booking_panel_widget(trip_plan_obj)</code>	机票/酒店面板：原样呈现 <code>trip_plan</code> 里已经落地确认的 <code>flights / hotels</code> 记录——注意这跟 <code>widgets.py</code> 的 <code>build_flight_picker_widget / build_hotel_picker_widget</code> 不是一回事，那两个是"聊天框里给用户挑的候选推荐"，这里是"已经确认、要显示在左侧行程里的记录"

`build_trip_map_widget` 返回结构（**分帧版，2026-09-11 起替换了原来的扁平 `markers / routes` 结构**）：

```
{
  "widget": "trip_map",
  "data": {
    "frames": [
      {
        "frame_id": "frame-1",
        "center": { "lng": ..., "lat": ... },
        "markers": [
          {
            "day": ..., "color": ..., "place": ..., "node_id": ..., "type": "attraction|meal|airport|...",
            "lng": ..., "lat": ...
          },
          ...
        ],
        "routes": [
          {
            "day": ..., "color": ..., "coordinates": [[{"lng": ..., "lat": ...}, ...]]
          },
          ...
        ],
        "unclustered_airports": [
          {
            "day": ..., "color": ..., "place": ..., "node_id": ..., "type": "airport", "role": ..., "flight_no": ..., "status": ..., "lng": ..., "lat": ...
          },
          ...
        ],
        "days_legend": [
          { "date": ..., "color": ... },
          ...
        ],
        "geocode_failures": [
          { "place": ..., "reason": ... },
          ...
        ]
      },
      ...
    ],
    ...
  }
}
```



```
"route_failures": [{"day":, "from":, "to":, "reason":}],
}}
```

- **为什么要分帧**：早期版本是所有 marker 挤进同一张地图，跨城市行程（比如“杭州玩三天+机票飞北京”）一旦机票起降机场跟行程主城市离得远，地图会被迫缩到能同时装下两座城市的比例尺，近处的景点全部挤成一个点，什么都看不清。改成按地理距离把 marker 分组，每组（帧）各自算自己的地图范围/比例尺，前端各画一个独立的 AMap.Map 实例，近处的点就能放大到看得清的程度
- **分帧算法**（`schedule_widgets.py` 里的 `_cluster_by_distance` + `_haversine_m`）：对当天的景点/餐饮/酒店 marker 用 haversine 距离做贪心单链聚类，阈值 `_FRAME_CLUSTER_THRESHOLD_M = 50_000`（50km）——两个点只要有一条 $\leq 50\text{km}$ 的链路就会被分进同一帧，超过阈值的自动分到不同帧
- **机票起降机场不参与聚类本身**，而是聚类结束、每帧的中心点算出来之后，拿机场坐标跟每一帧的中心点比距离，落在 `_AIRPORT_ATTACH_THRESHOLD_M = 80_000`（80km）以内就并入最近的那一帧（进 `frames[i].markers`），否则单独放进 `unclustered_airports`（不画在任何一帧里，避免为了容纳一个远处的机场把某一帧的比例尺又拉爆）——这是用户明确要求的规则：“起点和终点不算，直接忽略就行”
- 景点/餐饮 marker 的 `day / color` 按天分配；机票（`type: "airport"`，额外带 `role: "depart"|"arrive"`、`flight_no`、`status`）和酒店（`type: "hotel"`，额外带 `name / check_in / check_out`）的 `day` 固定是 `None`，颜色分别固定为深灰蓝/棕色（`_AIRPORT_COLOR / _HOTEL_COLOR`），不占用按天调色板
- 每帧内 `routes` 的坐标是把 `map_tool.route_between()` 返回的多段 `polyline` 展平成一条连续的 `[lng, lat]` 序列，直接给前端画线；一条路线按起点锚点归到最近的帧里；查询失败的那一段跳过并记进 `route_failures`，不影响其他天/其他段
- **字段约定**：`flights` 的 `from_ / to`、`hotels` 的 `address` 建议存能被地理编码识别的地名/地址（比如“杭州萧山国际机场”），不建议只存三字码（比如“HGH”）——高德地理编码认不出机场三字码，会直接进 `geocode_failures`

现状：三个 widget 已经接进 `server.py` 的 `GET /trip`，`web/index.html` 用高德 JS API 真的把地图画出来了（见 `server.py` + `web/index.html` 一节）；已经用真实 `AMAP_KEY` 端到端验证过，标点/连线/机票酒店坐标都是真实经纬度。

现状/限制：- 跟 `route_agent.py` 一样依赖 `AMAP_KEY`（后端查经纬度/路线用的那个，注意不是前端画图用的 `AMAP_JS_KEY`），没配置时 `markers / routes` 会是空的、`*_failures` 里全是查询失败记录（不会导致整体报错，自测+真实端到端联调都验证过这个降级路径）- `route_agent.py` 里已经算过一次相邻站点的交通方式/耗时，这里为了拿到完整 `polyline` 又独立查了一次路线（避免“展示层”反过来依赖某个 Agent 的内部计算结果），会有一点重复的高德 API 调用，demo/比赛规模的免费额度足够用，不是问题 - `POST /widget-response` 确认机票/酒店后会真的调 `trip_plan.add_flight() / add_hotel()`，`build_booking_panel_widget` / 机票酒店 marker 现在跑起来是有真实数据的（端到端联调过：选中机票+酒店 → `/trip` 能看到确认记录）- **机票起降机场地理编码不传 city**：`build_trip_map_widget(trip_plan_obj, city=...)` 的 `city` 参数只用于景点/餐饮/酒店这些“行程主城市内”的地点，机场坐标查询故意不传 `city` ——接真实 key 测试时踩到过一个坑：查“上海虹桥国际机场”时如果传了 `city="杭州"`，高德会把它强行匹配成杭州萧山机场附近的结果（两个机场坐标几乎重合），因为出发/到达机场天然可能分属两个不同城市，用行程主城市限定反而会查错

main.py -- 入口脚本

职责：纯胶水代码，不包含任何 Agent 逻辑。`from agents.orchestrator_agent import new_shared_state, orchestrate` 之后直接 re-export，`server.py` 还是 `import main` 调这两个函数，完全不用改。`__main__` 里是完整的端到端 demo（推荐 → 排路线 → 异常应变 → 打印最终行程）。

store.py -- 达人社区内容 + 历史记录

职责：达人社区的图文帖子存储 + 检索（两阶段检索第一阶段：按人格向量相似度筛选），以及行程反馈历史记录。

存储技术：Chroma 向量库（`orchestrator/data/chroma/`，本地文件持久化）存帖子；JSON Lines 文件（`orchestrator/data/history.jsonl`）存历史记录；图片本地落盘（`orchestrator/data/images/<post_id>/`），帖子里只存相对路径。

函数	作用
<code>save_image(post_id, filename, image_bytes)</code>	写一张图，返回存进 <code>content["images"]</code> 的相对路径
<code>resolve_image_path(相对路径)</code>	相对路径转本地绝对路径，读图用
<code>add_post(post_id, persona_vector, content)</code>	存一条帖子。 <code>content</code> 字段见下表
<code>query_similar_posts(persona_vector, top_k=5, city=None)</code>	两阶段检索第一阶段：按人格向量相似度找候选帖子，返回时带 <code>similarity_score</code> ； <code>verified_local=True</code> 的帖子会被优先加权（见下面说明）；传了 <code>city</code> 会在 Chroma 查询阶段就用 <code>where={"city": city}</code> 精确过滤，不是"先按相似度截 <code>top_k</code> 再筛掉不match的"（那样可能筛到结果不够甚至是空的）
<code>delete_post(post_id)</code>	删帖
<code>log_history(user_id, trip_id, record)</code>	追加一条行程反馈记录
<code>get_history(user_id=None)</code>	读历史记录，不传 <code>user_id</code> 读全部

`content` 字段（`add_post` 的第三个参数）：

字段	说明
<code>place</code> / <code>time_slot</code> / <code>avg_cost</code> / <code>rating</code> / <code>avoid_tips</code> / <code>verified_trip</code>	结构化字段，对齐 <code>agent-interfaces.md</code> 达人 Agent 输出契约
<code>caption</code>	帖子正文文字，可选

字段	说明
<code>images</code>	图片相对路径列表，可选，由 <code>save_image()</code> 生成
<code>tags</code>	标签列表，可选，跟 <code>images</code> 一样序列化存（ <code>tags_json</code> ），查询时还原回列表
<code>city</code> / <code>category</code> / <code>post_type</code> / <code>address</code> / <code>verified_local</code>	港澳达人数据库用的字段（见 <code>import_hk_macau_data.py</code> 一节）， <code>verified_local=True</code> 表示本地人认证来源

"本地人认证"优先加权是怎么做的： `query_similar_posts()` 先按 `top_k * 3` 多捞一些候选（不是只捞 `top_k` 个），把 `verified_local=True` 的帖子相似度乘一个固定系数 `_VERIFIED_LOCAL_BOOST = 1.15`，再按加权后的分数重新排序截到 `top_k`。这个"先多捞再重排"是必须的——如果直接对 Chroma 已经按原始距离截好的 `top_k` 结果加权，加权只能在这几条里面换个顺序，换不进被漏掉的本地人帖子，加权就没意义了。

待定/限制： - 内容相关性排序（两阶段检索第二阶段）没实现，留给调用方在 `query_similar_posts()` 的候选集里自己排 - 图片存本地文件系统，部署到 ModelScope Studio 时要换成对象存储（OSS/CDN），`images` 字段到时候存 URL 而不是本地路径，上层调用方式不变 - `_VERIFIED_LOCAL_BOOST` 系数（1.15）是拍的，没有做过效果对比调优，觉得加权效果不明显/太强可以直接改这个常量

standardize_hk_macau_data.py + import_hk_macau_data.py -- 港澳达人数据库

背景：组员手动整理了一份港澳（澳门/香港）达人推荐/避坑数据，存在仓库根目录的 `数据库原始.xlsx` 里，来源分两种： - **本地人认证**（Excel 里的"本地人澳门"/"本地人香港" sheet）：饮食/景点/Tips 分类推荐 + 单独一张避坑表 - **小红书**（"小红书澳门"/"小红书香港" sheet）：褒贬都有的普通帖子，不算本地人认证来源

这两种来源对应 `store.py` 里新加的 `verified_local` 字段——本地人认证的帖子在检索时会被优先加权（见 `store.py` 一节），小红书来源不加权。这个字段是原始数据自带的真实来源标记（组员整理的时候已经分好表了），不是靠算法从内容"判断"出来的。

两步流程（分开是为了标准化出错时不用重新灌一次向量库）：

脚本	作用
<code>standardize_hk_macau_data.py</code>	读 <code>数据库原始.xlsx</code> ，标准化字段 + 编号，写出 <code>data_sources/hk_macau_posts.json</code> 。不碰 Chroma
<code>import_hk_macau_data.py</code>	读标准化 JSON，用 <code>persona.infer_post_persona_vector()</code> 给每条帖子算一个人格向量，调 <code>store.add_post()</code> 灌进 Chroma

编号规则（城市前缀 + 类型字母 + 三位数字，类型内连续编号，不区分本地人/小红书来源）：

	澳门·推荐	澳门·避坑	香港·推荐	香港·避坑
编号格式	MF/MS/MT + 三位数字	MN + 三位数字	HF/HS/HT + 三位数字	HN + 三位数字
示例	MF001, MS001, MT001	MN001, MN002	HF001, HS001, HT001	HN001, HN002
说明	饮食/景点/Tips, 正常分类	全部统一放这里, 不分饮食/景点	同左	同左

解读：M=Macau, H=Hong Kong (城市前缀)；F=Food, S=Sight, T=Tips (推荐分类)；N=No (避坑专用, 统一放一起不细分)。

原始表格解析上的坑：Excel 里不同分类小节的列不是对齐的 (比如"本地人香港"的 Tips 小节没有单独的"名称"列, 内容直接写在名称那一格; "本地人香港"饮食小节比"本地人澳门"多一列"推荐人"), `standardize_hk_macau_data.py` 按每个小节自己的表头动态取列, 不能假设固定列位置——这个坑是解析的时候踩出来的, 写死列位置会导致数据错位。

当前数据量 (229 条, 跑 `python standardize_hk_macau_data.py` 会打印这个分布)：

前缀	条数	前缀	条数
MF	50 (本地人30+小红书20)	HF	19 (本地人9+小红书10)
MS	50	HS	20
MT	50	HT	20
MN	10	HN	10

已知数据缺口：香港饮食类本地人认证只有 9 条, 不是目标的 10 条——原始表格里就是这样, 组员应该是漏填了一条, 不是解析脚本的 bug, 不影响其他数据使用。

怎么重新跑：

```
python orchestrator/standardize_hk_macau_data.py # 改了 Excel 或标准化逻辑之后跑
python orchestrator/import_hk_macau_data.py      # 改了人格反推逻辑, 或者清空过 orchestrator/data/chrc
```

`import_hk_macau_data.py` 用的是 `upsert` (`store.add_post()` 内部调的), 同一个 id 重复导入会覆盖不会重复, 可以放心重跑。

待接事项： - 避坑类帖子 (MN / HN) 反推出来的人格向量是中性默认值 (见 `persona.py` 一节的已知局限), 检索排名上不占优势也不吃亏, 更合理的做法 (不管人格匹配度、只要地点/类型对上就该出现) 属于两阶段检索第二阶段, 还没实现 - `verified_local` 优先加权的系数 (1.15) 没有做过 A/B 效果对比, 是拍的经验值 - `content_agent.py` 的两阶段检索第二阶段接上之后, `category` (饮食/景点/Tips) 字段可以用来做更精细的"用户问吃的就优先出饮食类"这种过滤, 现在还没用上

trip_plan.py -- 旅游计划（行程/机票/酒店/天气异常）

职责：一次完整旅行的所有结构化信息，由多个 Agent 共同维护，最终汇总用于呈现。

顶层结构：

```
trip_plan = {
    "trip_id": "...",
    "flights": [...],          # OTA/酒店 Agent 维护
    "hotels": [...],           # OTA/酒店 Agent 维护
    "weather_alerts": [...],   # 异常应变 Agent 维护
    "days": {日期: day_plan}, # 行程 Agent 生成, 异常应变 Agent 增删改
}
```

景点通勤+餐饮的核心设计：每天一个"链表"，但不是指针式链表，而是**节点字典 + id 引用**（`day_plan["nodes"]` 是 `{node_id: node}`，每个节点有 `next_id` 指向下一个节点的 id，`day_plan["head_id"]` 是链表头）。这样设计是因为：- 异常应变 Agent 改行程时只需要动被影响的那一个节点、接一下前后 `next_id`，不用重发整天的数组 - 本质是个普通 dict，直接能存 JSON/传 HTTP，不需要额外的链表<->数组转换逻辑

节点字段：`type`（`"attraction" | "meal"`）、`place`、`arrival_transport`、`arrival_time`、`end_time`、`next_id`；`meal` 类型节点多一个 `meal_type`（早餐/午餐/晚餐/夜宵）。

函数	作用
<code>new_trip_plan(trip_id)</code>	造一个空旅游计划
<code>add_flight / add_hotel / add_weather_alert</code>	往对应列表追加一条记录
<code>get_or_create_day(trip_plan, date)</code>	拿到某天的 <code>day_plan</code> ，不存在就新建
<code>add_stop(day_plan, node_id, type_, place, arrival_transport, arrival_time, end_time, after_id=None, **extra)</code>	插入一个节点， <code>after_id=None</code> 插到最前面，否则插到该节点后面
<code>remove_stop(day_plan, node_id)</code>	删除节点，自动重连前后节点（异常应变 Agent 常用，比如景点临时关闭）
<code>patch_stop(day_plan, node_id, **fields)</code>	只改某个节点的部分字段，不动链表结构
<code>day_stops(day_plan)</code>	把链表还原成有序数组，渲染/地图面板用
<code>render(trip_plan)</code>	汇总成最终展示结构 (<code>flights / hotels / weather_alerts / days</code> ，每天的 <code>stops</code> 已经是有序数组)

现状：已经接进 `main.py` 的 `shared_state["trip_plan"]` , `agent_route` 会往里面加节点、`agent_exception` 会删节点/记天气异常。目前所有节点都写进同一个占位日期 `"day-1"` (`main.py` 里的 `_PLACEHOLDER_DAY`) , 还没做真正的多日期规划。

persona.py -- 人格变量

职责：定义"旅游人格"的具体维度结构，供达人/行程/OTA Agent 读取，反馈闭环用来校准。

维度设计 (能量化的维度都用了 0~1 连续分数，不是纯标签)：

维度	归属	类型	说明
<code>taste</code>	<code>stable_traits</code> (跨场景稳定)	固定词表 multi-hot	菜系标签，词表见 <code>_TASTE_VOCAB</code>
<code>novelty_score</code>	<code>stable_traits</code>	float 0~1	0=稳妥大众，1=小众冒险
<code>pace_score</code>	<code>scenario_traits</code> (按场景分开存)	float 0~1	0=完全休闲，1=完全特种兵
<code>budget_score</code>	<code>scenario_traits</code>	float 0~1	0=穷游，1=公务舱/总统套房/租车这种享受型消费； 硬过滤字段，不进相似度向量 ，用 <code>budget_filter_ok()</code> 按数值区间过滤
<code>social_mode</code>	<code>scenario_traits</code>	分类 (<code>solo / couple / family / friends</code>)	并列模式非程度光谱，向量里按 one-hot 编码
<code>interest_theme</code>	<code>scenario_traits</code>	固定词表 multi-hot	词表见 <code>_INTEREST_VOCAB</code>

`scenario_traits` 按"本次旅行模式" (`business_trip / vacation / family / solo_adventure` ...) 分开存，同一个人不同场景下这些值可以完全不同。

函数	作用
<code>new_persona(user_id)</code>	造一份空人格
<code>bootstrap_from_onboarding(user_id, scenario, answers)</code>	冷启动：从一份问卷答案组出初始 persona
<code>set_scenario_traits(persona, scenario, **fields)</code> / <code>get_scenario_traits(persona, scenario)</code>	读写某场景的特质，写入时会校验词表 + clamp 数值到 0~1
<code>update_stable_traits(persona, **fields)</code>	读写跨场景稳定特质，同样有校验

函数	作用
<code>apply_feedback(persona, scenario, dimension, new_value, reason="")</code>	按维度校准, 写入 + 留痕 (<code>feedback_log</code>) 。"该改成什么值"由调用方决定, 这里只负责写入
<code>budget_filter_ok(a_score, b_score, max_diff=0.25)</code>	判断两个 <code>budget_score</code> 是否够接近, 硬过滤专用, 独立于相似度向量
<code>compute_persona_vector(persona, scenario)</code>	拼出向量: [<code>novelty_score</code> , <code>taste multi-hot</code> , <code>pace_score</code> , <code>social_mode one-hot</code> , <code>interest_theme multi-hot</code>], 固定 21 维 (词表大小变了维度也会变, 加了"葡国菜"后从 20 变 21)
<code>infer_post_persona_vector(scenario, tags=None, avg_cost=None, category=None)</code>	港澳达人数据库导入专用: 这些帖子是组员手动整理的真实内容, 没有"发帖人自己的问卷答案", 用标签/人均/分类反推一个大致合理的人格向量, 见下面单独说明

`infer_post_persona_vector()` 是怎么反推的 (启发式估计, 不是精确画像): -

`_TAG_TO_TASTE` / `_TAG_TO_INTEREST` 两个关键词映射表, 对标签文本做子串匹配, 匹配上就计入对应的 `taste` / `interest_theme`; 匹配不上的标签 (比如"三代传承" "400年历史" 这种描述性但不构成人格维度信号的) 直接丢弃, 不强行凑 - `category` (饮食/景点) 也会补一条弱信号: 饮食→"美食探店", 景点→"人文历史" - `avg_cost` 线性换算成 `budget_score` (0~250 元映射到 0~1, 250 元封顶), 换算公式很粗糙, 不是精确定价模型 - 标签里出现"小众/冷门/隐世"这类词 → `novelty_score` 偏高 (0.75); 出现"网红/热门/必打卡" → 偏低 (0.3); 都没有就是中性 0.5 - `social_mode` 故意不猜——单条帖子看不出"适合独行/家庭/朋友", 留空对应 `compute_persona_vector()` 里那段 `one-hot` 全 0, 这是合法的"未指定"编码 - **已知局限**: 避坑 (避雷理由) 类帖子在标准化数据里没有 `tags` / `avg_cost` / `category`, 反推出来的人格向量是中性默认值 (`novelty=0.5`, `budget=0.5`, 无 `taste/interest`), 跟任何用户人格的相似度都不会特别高也不会特别低——这类帖子更适合"不管人格匹配度、只要地点/类型对上就该出现", 属于两阶段检索第二阶段 (内容相关性排序) 该管的事, 那部分还没实现

待定/限制: - `compute_persona_vector()` 是数值特征拼接, 不是真实语义 `embedding`, 以后接真实 `embedding` 模型可以整体替换掉函数体, 调用方 (`store.py`) 接口不用变 - 改 `_TASTE_VOCAB` / `_INTEREST_VOCAB` 词表会改变向量维度, 如果本地 Chroma 已经有存量数据, 改词表前要清掉 `orchestrator/data/chroma` 重新灌数据, 不然新旧向量维度对不上 (这个坑已经踩过一次, 这次加"葡国菜"也重新灌了一次数据) - 从一条用户反馈文本判断"该把哪个维度调成什么值"的算法没实现, 留给编排/达人 Agent 决定

server.py + web/index.html -- 呈现层 (网页)

职责: 把 `main.py` 的编排 Agent、`widgets.py`、`schedule_widgets.py` 包成 HTTP 接口 + 真实渲染, 配一个两栏网页——左边实时日程 (地图+每日时间线+机票酒店面板), 右边聊天框 (文字回复+四个插件卡片)。这是目前唯一"从对话到落地预订"整条链路能真的跑通的地方。

运行方式:

```
pip install flask python-dotenv
python orchestrator/server.py
```

然后浏览器打开 `http://127.0.0.1:5000`。地图能不能真的画出来，取决于 `.env` 里三个高德 key 有没有配全（见“环境准备”一节）；没配的话页面照样能跑，只是地图是空的、控制台会有一条警告。

接口（都是同一个 Flask app 提供，同源不用处理 CORS）：

接口	作用
GET /	返回 <code>web/index.html</code> ，服务端会把文件里的 <code>__AMAP_JS_KEY__</code> / <code>__AMAP_JS_SECURITY_CODE__</code> 占位符换成 <code>.env</code> 里的真实值再返回（这两个 key 不写进 git 里的 html 文件，跟其他密钥一样只活在 <code>.env</code> ）
GET /trip	返回 <code>trip_plan.render()</code> 的行程 + 额外三个字段 <code>trip_map</code> / <code>day_timeline</code> / <code>booking_panel</code> （分别是 <code>schedule_widgets.py</code> 那三个函数的输出），左侧日程面板用这个渲染
POST /chat	body 传 <code>{"message": "..."} </code> ，内部调 <code>main.orchestrate()</code> ，返回编排 Agent 的输出（ <code>chat_reply</code> / <code>community_panel</code> / <code>map_panel</code> / <code>widgets</code> ）
POST /widget-response	body 传 <code>{"widget": "attraction_picker"\ "flight_picker"\ "hotel_picker", "selected": [...]}</code> ， <code>selected</code> 是前端从对应 widget 的 <code>options</code> 里原样拿到的候选对象（不是前端自己编的字段，跟 <code>widgets.py</code> 里“LLM 只能选真实 ID”是同一个防幻觉思路）。景点选中后调 <code>route_agent.run()</code> 排行程；机票/酒店选中后调 <code>trip_plan.add_flight()</code> / <code>add_hotel()</code> 确认预订

前端逻辑（`web/index.html`，原生 HTML/CSS/JS + 高德地图 JS SDK，没引入前端框架）：

- 发消息 → 调 `/chat` → 显示文字回复 → 把返回的 `widgets` 数组按类型分发渲染（`post_list` 是横滑卡片；`attraction_picker` / `flight_picker` / `hotel_picker` 共用同一套“复选框 + 确认按钮”组件，`max_select` 决定最多能勾几个）→ 再调一次 `/trip` 刷新左侧日程
- 三个“选择型”widget 点“确认选择”之后：把勾中的候选对象原样 `POST /widget-response`，成功后往聊天记录里加一条系统提示（“已确认：xxx”），再刷新一次左侧日程
- 左侧地图**不再是页面加载时初始化一次的单个 `AMap.Map`**（2026-09-11 起改为分帧渲染，跟后端 `trip_map.data.frames` 的结构对应）：每次 `/trip` 刷新，`renderMap()` 先把上一轮所有帧的 `AMap.Map` 实例逐个 `destroy()`，再按 `frames` 数组动态生成对应数量的 `.map-frame` 容器（`#map-frames` 下面纵向排列，每帧一个独立的 220px 高地图 div + “第 N 组 · X 个地点”标签），`drawFrameMap()` 给每帧各自 `new` 一个 `AMap.Map` 实例、只画这一帧自己的 `markers` / `routes`，各帧自动按自己的点位算合适的缩放级别（不用整条行程的极值），互不干扰
- 景点/餐饮用 `AMap.CircleMarker` 按天上色，机票/酒店 marker 固定深灰蓝/棕色（颜色跟 `schedule_widgets.py` 里的常量对应，改了那边记得这边也要改），路线用 `AMap.Polyline` 按天上色，标记点击会弹 `AMap.InfoWindow` 显示地点名（这部分单帧内部的画法逻辑跟改分帧之前一样，没变）
- `data.unclustered_airports`（离行程主体太远、没并进任何一帧的机场）渲染成 `#map-frames` 下方一行文字提示（“距离行程较远，未画在地图上：xxx”），不占用地图画布

- 每日行程时间线现在读 `trip.day_timeline` (带颜色) 而不是原始的 `trip.days`, 模块颜色跟地图上同一天的颜色对得上

现状/限制: - 全局只有一个进程内共享状态 (`server.py` 里的 `_state`), 是单会话 demo, 没有登录/多用户/并发处理, 仅供本地演示, 不要直接这样部署到公网 - 已经端到端联调过完整链路: "推荐+排路线+查机票酒店"发过去 → 右侧出现 `flight_picker / hotel_picker` → 模拟前端 `POST /widget-response` 选中一个航班一个酒店 → 再查 `/trip` 能看到 `flights / hotels` 里多了确认记录 (这一步是直接打 API 验证的, 没配 `AMAP_JS_KEY` 时浏览器里的地图看不到, 但数据链路是通的) - 社区图文面板 (三面板设计里"逛社区帖子墙"那块, 跟聊天框里的 `post_list` 不是一回事) 还没做进网页 - 地图是"重新全量清空再画", 不是增量更新, 行程节点很多的时候会有一点点闪烁, demo 规模不明显

待接事项

`main.py / server.py` 已经把所有 Agent + 两套 widgets 串成一条完整链路: 跑 `python orchestrator/main.py` 能看到一次"推荐→规划路线→异常应变→重新渲染行程"的端到端流程; 跑 `python orchestrator/server.py` 打开网页, 能看到"聊天推荐→勾选景点/机票/酒店→确认→左侧地图/时间线/机票酒店面板更新"这条更完整的闭环真的在跑 (已端到端联调验证过)。还剩这几处没做, 都不阻塞基本演示:

1. `ota_hotel_agent` 还是纯占位假数据 (固定一条机票一条酒店), 没有真实比价/查库存来源可接
2. `route_agent` 目前所有节点都写进同一个占位日期 `_PLACEHOLDER_DAY = "day-1"`, 没有真正的多日期规划——这意味着"按天上色"这个视觉设计在真实多日行程里还体现不出来 (永远只有一种颜色); 交通方式/耗时已经接了高德地图 API 真实计算, 但到达/结束的具体钟点时间还是占位文字 "待定"
3. `exception_agent` 用整句用户消息去子串匹配地点名字, 很粗糙 (比如"西湖"两个字出现在消息里就命中), 真实版本应该先做实体识别抽出具体地点
4. 两阶段检索第二阶段 (候选集内部按内容相关性排序) 还没实现, `content_agent` 里 `location_hint` 参数目前没用上
5. 反馈闭环 (用户点评行程 → 校准 persona) 还没接: `store.log_history()` 记录和 `persona.apply_feedback()` 校准都写好了, 但没人在 `orchestrate()` 里调用它们
6. `map_tool.py` 目前只查"两点之间", 没做"多点最优顺序"规划 (比如给定 5 个景点, 没有算出最优游览顺序, 只是按用户/LLM 给的顺序排)
7. 三个高德 key 已经申请配置好并真实验证过 (西湖→灵隐寺路线、机场/酒店坐标都是真实高德数据)
8. 讨论过的其他 widget 想法还没做: 反馈评分插件、异常变更确认插件、人格问卷引导插件
9. 单会话全局 state (`server.py` 里的 `_state`), 没有登录/多用户/并发处理, 真要多人同时用需要重新设计状态管理
10. 港澳达人数据库 (229 条, 见 `standardize_hk_macau_data.py` 一节) 已经标准化+导入 Chroma, `verified_local` 优先加权、`city` 硬过滤 (`content_agent._extract_city()` 子串匹配) 都接上了并真实验证过 (问香港只出香港、问澳门只出澳门); 但避坑类帖子的人格向量是中性默认值、`category` (饮食/景点/Tips) 字段还没用来做精细过滤, 这两个属于两阶段检索第二阶段 (第4条) 的范畴