

orchestrator/ 代码说明

给第一次看这份代码的人快速建立地图用的开发文档。`main.py` 只是薄薄的入口胶水代码，真正的 5 个 Agent 各自一个文件放在 `agents/` 目录下，`persona/store/trip_plan` 三个模块已经被对应的 Agent 接起来了（具体接了什么见文末），只有 OTA/酒店 Agent 还是纯占位假数据。

设计背景/接口契约见 [agent-architecture.md](#)（为什么这么分 Agent、为什么中心化编排）和 [agent-interfaces.md](#)（字段契约、原本的 Dify 方案，后来改成直接写 Python）。

环境准备

```
pip install openai python-dotenv chromadb
```

在 `orchestrator/.env` 里写这几行（这个文件已经在 `.gitignore` 里，不会被提交）：

```
PARATERA_API_KEY=你的key
AMAP_KEY=你的高德Web服务API Key
AMAP_JS_KEY=你的高德Web端(JS API)Key
AMAP_JS_SECURITY_CODE=你的安全密钥
QWEATHER_KEY=你的和风天气API KEY
QWEATHER_API_HOST=你的和风天气专属API Host
```

高德的 key **分三样东西，缺一不可都不行**： - `AMAP_KEY`： **Web服务** 类型，后端用（`map_tool.py` 查地理编码/路线） - `AMAP_JS_KEY`： **Web端(JS API)** 类型，前端画地图用——注意这是另一个应用/另一个 key，不能跟上面那个通用 - `AMAP_JS_SECURITY_CODE`： 安全密钥，高德 JS API 2.0 版本强制要求，在申请 `AMAP_JS_KEY` 的同一个应用页面能找到

都在 <https://lbs.amap.com> 控制台"创建应用"里申请（一个应用可以同时创建 Web服务 + Web端(JS API) 两个 key，安全密钥在创建 Web端(JS API) key 的时候会一起给）。个人开发者未认证 6000次/天，实名认证后 30万次/月，demo 阶段够用。

和风天气（`weather_tool.py` 用，灾害预警）去 <https://dev.qweather.com> 控制台"项目管理"申请： - `QWEATHER_KEY`： 创建凭据时选 **API KEY** 类型，不要选 JWT（JWT 要自己写签名逻辑，demo 规模没必要） - `QWEATHER_API_HOST`： 同一个项目页面上能看到，形如 `xxxxxxxxxx.re.qweatherapi.com`，**不用带** `https://` 前缀——2023 年后注册的新账号是"一账号一专属域名"，公共的 `devapi.qweather.com` 对新 key 直接返回 404，必须用这个专属域名

个人开发者免费版 1000次/天，灾害预警接口在免费的 8 个基础接口里（辐射/海洋/热带气旋等付费专项接口不在内，用不上）。

每个文件都能直接 `python orchestrator/<路径>.py` 单独跑（包括 `agents/` 里的 5 个文件），文件末尾的 `if __name__ == "__main__":` 都是自测代码，可以照着抄用法。

目录结构

```
orchestrator/
  llm_tool.py          # 通用 LLM 调用工具，跟"编排"本身无关，谁都能 import
  map_tool.py          # 通用地图工具（高德地图 API）：地理编码 + 路径规划
  weather_tool.py      # 通用天气工具（和风天气 API）：灾害预警查询，给异常应变 Agent 用
  hotel_tool.py        # 通用酒店工具（道旅 RollingGo）：真实酒店搜索 + 房型报价，给 OTA/酒店 Agent 用
  agents/
```

```
orchestrator_agent.py      # 编排 Agent: new_shared_state + classify_intent + orchestrate
content_agent.py          # 达人/内容 Agent
route_agent.py            # 行程/路线 Agent
ota_hotel_agent.py        # OTA/酒店 Agent (酒店真数据, 机票还是纯占位)
exception_agent.py        # 异常应变 Agent (提案制, 见对应一节)
restaurant_agent.py       # 餐厅技能 (fellow 分支合并进来): 澳门模拟餐厅演示, 带界数工具调用循环
widgets.py               # 展示插件: 右侧聊天框里的富交互小组件, 跟 Agent 逻辑解耦
schedule_widgets.py       # 左侧日程面板展示组件 (地图+连线、每日时间线、机票酒店面板), 跟 widgets.py 同一个分离
nearby_sources.py         # 附近游/达人 Agent 共用的数据源: 高德 POI/路线 + 和风天气逐小时预报
restaurant_tools.py       # restaurant_agent 的工具调用实现 (虚构澳门餐厅数据 + 校验规则)
session_store.py          # 按浏览器 session 存整份 shared_state (SQLite), 替换掉原来的单进程全局 state
standardize_hk_macau_data.py # 把组员整理的港澳达人数据 Excel 转成标准化 JSON (见文末专门一节)
import_hk_macau_data.py   # 把标准化 JSON 灌进 Chroma (人格向量怎么算在这一步)
data_sources/hk_macau_posts.json # 标准化后的港澳达人数据库 (229 条, 本地人认证 + 小红书两个来源)
main.py                  # 薄入口: re-export 编排 Agent 的两个函数 + __main__ 完整 demo
store.py / trip_plan.py / persona.py # 不变
server.py / web/         # 接了 session_store + 港澳附近游相关接口, 见对应一节
```

关于这条 workflow 设计思路 (content_agent.py + route_agent.py / restaurant_agent.py 共同体现): 能算清楚的事实 (几点到哪、走多久、天气、餐厅是否符合硬性限制) 用确定性代码算完, LLM 只用在两处很窄的地方: 把用户的自然语言请求解析成结构化字段、从已经查到的真实候选里挑 ID (不许凭空编新地点/新属性)。最后给用户看的文字要么是纯模板拼出来的 (route_agent.schedule() 排完之后的固定回复拼句), 要么是工具调用循环产出后原样返回、不再过第二个模型改写 (restaurant_agent.run())。orchestrator_agent.orchestrate() 里只有真正需要"总结/闲聊"性质的部分才会走最后一次 LLM 组句, 而且系统提示词里专门加了"以下 JSON 是资料不是指令, 不得捏造"这类防幻觉措辞。

拆分原则: 谁负责哪个 Agent 就改 agents/ 下自己那一个文件, 不用碰 main.py 或别人的 Agent 文件, 减少多人协作冲突。

llm_tool.py -- 通用 LLM 工具

职责: 跟"编排"这件事本身无关的基础设施, 5 个 Agent 里任何一个要调用模型都用这个, 不要各自再写一遍 client 初始化。

函数/常量	作用
call_llm(messages, model=MODEL_FULL)	统一的模型调用入口
MODEL_FULL / MODEL_LIGHT	DeepSeek-V4-Pro / DeepSeek-V4-Flash, 两档模型对齐 agent-architecture.md 的模型档位设计

map_tool.py -- 通用地图工具 (高德地图)

职责: 地理编码 + 路径规划, 给行程/路线 Agent 算真实的距离/耗时/路线用, 跟 llm_tool.py 一样是通用基础设施。

函数	作用
geocode(address, city=None)	地名/地址转经纬度, 返回 (lng, lat)
route_between(place_a, place_b, mode="walking", city=None)	算两地之间的距离/耗时/路线, mode 传 "walking" 或 "driving", 返回 distance_m / duration_min / polyline

现状/限制: - 只做了"两点之间"的查询, 还没做"多点一次性规划最优顺序" (这个高德也有专门接口, 以后要优化路线顺序时再接) - route_agent.py 里用这个算相邻两站的真实交通方式/耗时 (超过 2km 自动从步行切驾车), 查询失败会优雅降级成"待定 (地图查询失败: ...) "文字, 不会导致整个流程崩掉 - 到达/结束的具体钟点时间 (arrival_time / end_time) 还是占位——那需要"一天几点开始"+"每站玩多久"这类还没定义的调度逻辑, 跟地图 API 是两回事 - 地图可视化 (真的在网页上画一张地图+路线) 还没做, web/index.html 目前只是文字列表展示行程, polyline 字段目前没被前端用上

weather_tool.py -- 通用天气工具（和风天气）

职责：和风天气的两块能力——灾害预警（给异常应变 Agent 判断"这个城市现在是不是真的有极端天气"）、逐小时预报（给港澳附近游 workflow 算"这个时段要不要带伞"）。跟 map_tool.py 一样是通用基础设施。

函数	作用
<code>get_active_warnings(location, city=None)</code>	查某个地名当前生效的灾害预警，返回列表，每条 { <code>"headline"</code> , <code>"event_type"</code> , <code>"severity"</code> , <code>"description"</code> , <code>"effective_time"</code> , <code>"expire_time"</code> }；没有预警返回空列表（正常情况，不是错误）
<code>get_hourly_forecast(lng, lat, hours=240)</code>	查某个坐标未来最多 240 小时（10 天，免费版上限）的逐小时预报，返回列表，每条 { <code>"time"</code> , <code>"temperature_c"</code> , <code>"rain_probability"</code> , <code>"condition_text"</code> }；直接传经纬度（不查地名）， <code>nearby_sources.py</code> 已经有 POI 坐标就不用再地理编码一次

- `severity` 取值：`unknown / minor / moderate / severe / extreme`，越靠后越严重——`exception_agent.check_weather()` 用这个字段决定 `needs_replan` 要不要标 `True`（只是提示信号，不会自动改行程，见 `exception_agent.py` 一节）
- `get_active_warnings()` 按经纬度查（`/weatheralert/v1/current/{lat}/{lon}`），不需要先转和风天气自己的 `LocationID`，所以直接复用 `map_tool.geocode()` 拿坐标，少一次网络调用；`get_hourly_forecast()`（`/weather/v1/hourly/{lat}/{lon}`）同理，且额外传了 `localTime=true`，返回的 `time` 字段直接是当地时间字符串（不带时区偏移），不用再手动转时区
- 和风天气新账号是"一账号一专属域名"：**2023 年后注册的 key 用公共的 `devapi.qweather.com / geoapi.qweather.com` 会直接 404，必须去控制台"项目管理"页面找到这个 key 专属的 API Host（形如 `xxxxxxxxxx.re.qweatherapi.com`），配进 `.env` 的 `QWEATHER_API_HOST`（见"环境准备"一节）——这是接入过程里踩的第一个坑，实测过公共域名连 key 是否有效都判断不出来，报错也不明显（直接 404 空 body，不是 JSON 格式的错误信息）
- 2026-09-11 用真实预警数据验证过：查询当时有台风影响的海南（海口）能查到 2 条真实的雷电/大风黄色预警，字段解析正常；查没有预警的城市（香港/澳门）返回空列表，也验证过降级路径
- 2026-09-12 `get_hourly_forecast()` 真实数据验证过：`nearby_sources.weather()` 端到端跑通，拿到真实的澳门逐小时气温/降雨概率

hotel_tool.py -- 通用酒店工具（道旅 RollingGo）

职责：真实酒店搜索 + 房型报价，给 `ota_hotel_agent.py` 用，2026-09-13 接入。跟 `map_tool.py / weather_tool.py` 一样是通用基础设施。

函数	作用
<code>search_hotels(place, place_type, origin_query, check_in_date=None, stay_nights=1, star_min=None, size=5)</code>	搜酒店候选，返回列表，每条带 <code>hotel_id / name / address / star_rating / price_per_night / lat / lng / image_url / booking_url / ameniti</code>
<code>get_hotel_detail(hotel_id, check_in_date, check_out_date, adult_count=2, room_count=1)</code>	查某个酒店的具体房型报价，返回房型列表，带 <code>room_name / price_per_night / bed_type / meal / cancelable / cancel_policy</code>

- 数据源：**道旅（DIDA Travel，官方宣传"全球第三大酒旅 B2B 公司"）的 RollingGo 免费开放接口，200 万+真实酒店库存，个人/企业开发者均可免费申请、目前阶段无调用上限（官方说明是"目前阶段"，不保证长期不变）。去 `https://travelportal-partner-center.dida.com/register?lang=zh` 注册，0 等待即时拿到 key。**这一步是用户自己注册的，不是我能代办的事**（涉及个人账号信息）。
- 协议是 MCP，不是普通 REST：**服务本质是个 Model Context Protocol server（`https://mcp.rollinggo.cn/mcp`），但直接用 `requests` 发 JSON-RPC 2.0 请求过去就行，不用接一整套 MCP 客户端框架——`method` 固定 `"tools/call"`，`params.name` 是工具名，`params.arguments` 是工具参数。**真正的业务数据包了两层：**`response["result"][0]["content"]` 是一段

- JSON 字符串，要再 `json.loads()` 一次才能拿到真正的酒店数据（第一次接的时候没注意到这层，拿到的一直是“文本”外壳，调试了一下才发现）。请求头必须带 `Accept: application/json, text/event-stream`，缺了服务端直接 400。
- **search_hotels() 返回的 price_per_night 是估算值：**源接口 `searchHotels` 只返回整个入住期间的总价（`lowestPrice`），本模块按 `stay_nights` 算术平均换算成“每晚”，不是真的按天查一次；想要某个具体房型精确到每晚多少钱、取消政策，要再调一次 `get_hotel_detail()`（目前 `ota_hotel_agent.py` 没有自动调这一步，只在候选列表阶段用估算价）。
 - **只做只读查询，不碰下单/支付：**官方还有一个走 OAuth 登录 + 人工二次确认的命令行工具（`rgh` 系列，能真实下单付款），调研这个数据源的时候顺带发现的，明确决定不接进这种自动跑的后端 Agent 流程——那类操作必须是用户本人在自己的终端里主动触发，不适合塞进 `orchestrate()` 这种自动化链路。
 - 2026-09-13 真实数据验证过：搜“大三巴附近四星酒店”拿到 5 家真实澳门酒店（假日酒店/华都酒店等），真实价格/地址/坐标/图片/设施；`getHotelDetail` 查到真实房型（假日高级房/高级双床房等）、真实每晚价格、真实取消政策。

agents/orchestrator_agent.py -- 编排 Agent

职责：星型架构的中枢。接收用户消息 → 意图识别 → 决定调用哪几个子 Agent/workflow → 汇总结果 → 生成回复。对应 [agent_interfaces.md 第三节](#) 的节点拓扑，只是从 Dify 可视化节点换成了 Python 函数。模型档位用 `MODEL_FULL`（全系统推理最重）。

2026-09-14 重构：达人 Agent 收窄成“提出候选”，编排 Agent 统一负责调度+对话，排时间归 route_agent.py——`nearby`（港澳附近游）不再是独立短路的 workflow，并入了达人 Agent 内部（见下面 `content_agent.py` 一节），`nearby_planner.py` 整个删除，逻辑吸收进 `content_agent.py`（候选生成）和 `route_agent.py`（排时间）。这是继 2026-09-11 合并 `fellow` 分支之后的第二次大调整。

函数	作用
<code>new_shared_state(user_id, scenario="vacation", onboarding_answers=None)</code>	造一份共享状态： <code>persona + trip_plan + messages / pending_widgets</code>
<code>classify_intent(user_message, history=None)</code>	调模型判断这轮要触发 <code>nearby / content / restaurant / route / booking / exception / cancel</code> 里的哪个
<code>orchestrate(user_message, shared_state)</code>	主流程，返回 <code>(output, shared_state)</code>

`orchestrate()` 分发逻辑（不再有整体短路）：1. `nearby / content` 二选一调达人 Agent：`nearby` 命中传 `mode="nearby"`，否则（`content` 命中且非 `restaurant`）传 `mode="trip"`——两者共用 `content_agent.run()` 同一个函数，细节见下面一节 2. 达人 Agent 返回 `clarification_needed`（`mode="nearby"` 解析不出起点时）就直接把这句追问当回复整轮返回，不再往下跑——跟以前 `nearby_planner.from_chat()` 解析失败时的短路行为一致 3. `route` 或 `nearby` 命中，且达人 Agent 真的给出了候选，就调 `route_agent.schedule()` 排时间（`nearby` 命中给单日、`hours / origin` 用达人 Agent 解析出的；否则给 `_extract_day_count(user_message)` 提取出的天数，正则匹配“N日/N天”，提取不到默认 1 天，封顶 14 天）4. `booking / exception / cancel` 分发方式不变 5. 回复优先级：`restaurant > cancel > 通用 LLM 组句`（其中只有通用 LLM 组句这一条会真的调模型生成自由文本，前两条都是固定模板拼句）

cancel 意图（`exception_agent` 提案制“确认后执行”缺口的第一个真实触发路径）：区别于 `exception`（用户在了解情况，还没决定要不要动行程，命中只产生未验证提案，不执行），`cancel` 是用户直接下达删除指令，消息本身就是确认。`orchestrate()` 里 `_handle_cancel()` 复用 `exception_agent.run()` 的子串匹配定位地点，找到了就立刻调 `exception_agent.apply_adjustment()` 真删。删除成功会固定追问“是补新活动还是重新排”，但这句追问之后没有对应的“清空重排”能力（`route_agent.schedule()` 目前只会往 `trip_plan` 里新增天数，不会清空已有内容重排），是待接事项。

`orchestrate()` 返回的 `output` 里 `map_panel` 现在是 `route_agent.schedule()` 的返回结构（`{"days":, "weather_reminders":, "unscheduled":}`），不再是旧版 `{"route": [...]}` 那种扁平结构——前端 `web/index.html` 还没跟着改，这是已知的前端配套缺口。

agents/content_agent.py -- 达人/内容 Agent

职责：提出候选景点/美食供编排 Agent 筛选，不管排时间（排时间是 `route_agent.schedule()` 的事）。2026-09-14 重构：`nearby` 并入这里，两种场景共用同一条“查真实周边 POI + 社区口碑复核”流水线。模型档位 `MODEL_FULL`；`mode="nearby"` 时会有 一次 `MODEL_LIGHT` 调用解析请求参数，`mode="trip"` 目前仍是纯向量检索，没有实际用到 LLM。

`run(shared_state, location_hint, mode="trip", top_k=3)`：

mode	行为
"trip"（默认）	先按人格向量从社区帖子库筛几个种子（ <code>store.query_similar_posts()</code> ，多捞 <code>top_k*5</code> 过滤掉 <code>category=="Tips"</code> 的再截到 <code>top_k</code> ——空白人格实测会系统性偏向 Tips 帖子，过滤完一个不剩就退回未过滤结果兜底，不摆烂）；再对每个种子（ <code>category</code> 是 Food/Sight 的，Tips 跳过）分别调 <code>_nearby_plan()</code> 查真实周边 POI，汇总去重
"nearby"	跳过人格检索种子； <code>_parse_nearby_request()</code> 用 <code>MODEL_LIGHT</code> 从 <code>location_hint</code> 解析出起点/游览小时数，解析不出返回 <code>clarification_needed</code> ；解析出来就用 <code>nearby_sources.find_origin()</code> 查真实起点坐标，调一次 <code>_nearby_plan()</code>

`_nearby_plan(origin, city, persona_vector)`：统一的“周边探索”接口，两种场景都调用——查 `nearby_sources.nearby()` 真实高德周边 POI，再对每个 POI 查 `store.find_posts_by_place()` 看社区库有没有人评价过，评价人的人格向量跟当前用户的用 `persona.cosine_similarity()` 比对。排序策略：有人格匹配分的排最前，有评价但算不出匹配分的其次，完全没评价的排最后但**仍然保留**（229 条帖子覆盖的地点有限，多数真实 POI 大概率查不到匹配评价，不能因为没数据就排除）。地点匹配是精确字符串匹配（POI 名字 vs 帖子 `place` 字段），命中率本来就不高，是已知局限。

已知坑（2026-09-14 实测踩过）：给种子地点找坐标不能用 `map_tool.geocode()`（高德 `geocode/geo` 接口），对“渔人码头”这类多地重名的地标在港澳场景下经常查到内地同名地点（实测查出过跑去河北秦皇岛/云南的坐标）——改用 `nearby_sources.find_origin()`（高德 `place/text` + `citylimit` 硬限定）才可靠，这个 `session` 之前查机场/其他地标也一直在用这个函数，是港澳场景下地理编码的标准做法。

返回 `{"recommendations": [... 候选, place / city / category / source ("社区帖子"|"高德POI")/ persona_match_score ...]}`，`"nearby_params": {"origin":{"lng,lat,name}, "hours":int} | None, "clarification_needed": str | None}`。

agents/route_agent.py -- 行程/路线 Agent

职责：把地点写进 `trip_plan` 的行程节点。模型档位 `MODEL_LIGHT`，纯结构化写入，没接 LLM。两个入口：

函数	作用
<code>run(shared_state, places, time_budget=None, city=None)</code>	旧接口， <code>places</code> 是地点名字字符串列表，全部按顺序写进同一个占位日期 <code>_PLACEHOLDER_DAY = "day-1"</code> 。 <code>server.py</code> 的 <code>POST /widget-response</code> （ <code>attraction_picker</code> 确认）还在用这个，2026-09-14 重构时保留没动
<code>schedule(shared_state, candidates, city, mode="trip", time_budget_days=1, hours=None, origin=None)</code>	2026-09-14 新增 ，统一排时间接口，给编排 Agent 调用

`schedule()` 是这次重构的核心新增：`candidates` 是 `content_agent.run()` 产出的候选（带经纬度的才会被排班，没坐标的直接进 `unscheduled`）。`mode="nearby"`：单日短途，`origin` 是真实起点坐标，贪心选近的凑够 `hours` 预算；`mode="trip"`：按 `time_budget_days` 天数贪心分配，每天默认 09:00 排到 20:00、最多 6 站，**真正新开 day-N 天数**（不再是单一占位日期，`route_agent.run()` 长期悬而未决的“没有真正多日期规划”问题到这里解决了）。到达/结束时间是真推进时间游标算出来的，交通耗时查 `map_tool.route_between()`（2km 阈值切驾车，跟旧版同一个阈值）；天气只查最后一站附近未来 24 小时（避免每站都查一次浪费调用次数）。

内部拆了几个小函数：`_greedy_order()`（贪心选近的，纯几何不算时间）、`_place_day()`（把选好的顺序真实排进一天、算真实到达时间、超时的切进 `unscheduled`）、`_real_leg()`（查两点间真实交通，跟 `run()` 用的 `_estimate_transport()` 是姐妹函数，一个返回格式化合字符串，一个返回原始数据方便推进时间游标）。

已知限制： `_real_leg()` 内部还是走 `map_tool.route_between()`（连带用到的 `geocode/geo`），对港澳场景两个挨得很近的真实地点偶尔会查询失败（实测澳门大三巴附近几个景点之间出现过“待定（地图查询失败）”，这是 `map_tool.route_between()` 本身的已知限制，不是这次新引入的问题，降级行为（标“待定”、继续排下一站）是既有的、已接受的处理方式。

agents/ota_hotel_agent.py -- OTA/酒店 Agent

职责：查库存/比价。模型档位 `MODEL_LIGHT`。**酒店这半边 2026-09-13 起接了真实数据**（`hotel_tool.py`，道旅 RollingGo），**机票这半边还是纯占位假数据**——机票比价没有免费的个人开发者可用来源（携程/去哪儿这类都是企业商家合作性质，不对个人开发者开放，调研过没有绕开的办法）。字段补全到“用户选中后能直接落地”的程度：机票候选带 `flight_no / from_ / to / depart_time / arrive_time / status`，酒店候选带 `address / check_in / check_out`（`check_in / check_out` 会用 `date_range` 参数填，格式“开始日期~结束日期”，没传就默认“明天起 2 晚”）。这样 `POST /widget-response`（见 `server.py` 一节）收到用户选中的候选后，能直接拿这些字段调 `trip_plan.add_flight()` / `add_hotel()`，不用现造字段。

`run(shared_state, location, date_range=None, category=None, user_message=None)`：`location` 没传就从 `shared_state["city"]` 兜底（再没有就是 `demo` 默认“澳门”），`user_message` 传了会原样喂给 `hotel_tool.search_hotels()` 当查询意图描述（比拼关键词更准，`orchestrator_agent.py` 的 `booking` 分会把这轮用户原话传进来）；真查失败（key 没配/网络问题）优雅降级成空酒店列表 + `hotel_query_error` 字段，不会抛异常炸穿 `orchestrate()`。

`orchestrate()` 里 `booking` 意图命中时会把这里返回的 `candidates` 分别喂给 `widgets.build_flight_picker_widget()` / `widgets.build_hotel_picker_widget()`（按 `candidates` 里的 `provider_type` 字段分流，见下面 `widgets.py` 一节），机票假数据、酒店真数据混在同一个候选列表里，两个 `widget` 都能出内容。

已知缺口（2026-09-13 真实端到端测试时发现）：`orchestrate()` 目前没有从用户消息里提取日期，`date_range` 从来没被传给 `run()`，酒店查询永远用默认的“明天起 2 晚”。真实数据接上之后这个问题第一次变得可见——之前反正是假数据，日期对不对不影响观感；测试时间“9月20-22号”的酒店，LLM 最后收尾组句时诚实地发现拿到的是默认日期的价格，主动跟用户说明了“这不是你问的那两天的价格”（防幻觉提示词生效的证据，没有硬装作数据对上），但功能上确实没做到“按用户说的日期查”。修法待定：可以简单加一段日期正则提取，也可以扩展 `classify_intent` 顺便做实体抽取，需要先决定思路。

agents/exception_agent.py -- 异常应变 Agent

职责：提案制（2026-09-11 合并 `fellow` 的 `codex/integrate-travel-guardian` 分支后定型）——`run()` / `check_weather()` 两条评估路径都只评估、不执行，`requires_confirmation` 恒为 `True`，谁都不直接碰 `trip_plan`；`apply_adjustment()`（2026-09-14 新增）才是“用户确认后真正执行”的那一步。模型档位架构文档里写的是“中等模型”，目前只有 `MODEL_FULL` / `MODEL_LIGHT` 两档，先待定。

函数	作用
<code>run(shared_state, event_type, event_detail=None)</code>	按地点名字匹配 <code>trip_plan</code> 里的行程节点（纯子串匹配， <code>event_detail</code> 是用户整句话），命中就列进 <code>affected_locations</code> ， 不删 。 <code>event_verified</code> 恒为 <code>False</code> ——纯粹是“消息里提到了这个地名”，没有验证过是不是真的发生了
<code>check_weather(shared_state, city)</code>	真查 <code>weather_tool.py</code> （和风天气灾害预警），不依赖用户有没有主动提到天气——只要能确定城市就查真实数据。 <code>event_verified</code> 恒为 <code>True</code> ：跟 <code>run()</code> 的关键区别是这条数据来自真实 API，不是子串猜的，但一样不自动改行程
<code>apply_adjustment(shared_state, place)</code>	真删 ：按地点名字（精确匹配，通常就是前两个函数提案里 <code>affected_locations</code> 的某一项）从 <code>trip_plan</code> 里删掉对应节点，可能跨天/命中多个。返回 <code>{"cancelled": [...], "count": N}</code> ， <code>count=0</code> 不算错误，可能是提案之后行程又被改过

`run()` / `check_weather()` 返回同一套评估契约：
`has_warning / needs_replan / requires_confirmation / event_verified / suggested_adjustment`（`run()` 版本另外还有 `affected_locations`）。`apply_adjustment()` 是单独一套“执行结果”契约，不跟评估契约混在一起。

`apply_adjustment()` 底层调的是 `trip_plan.py` 新增的两个函数: `cancel_stop_by_id(trip_plan, node_id)` (按 `node_id` 精确删一个) 和 `cancel_stops_by_place(trip_plan, place)` (按地点名字删, 可能命中多个) ——这两个是对 `trip_plan.remove_stop(day_plan, node_id)` 的封装, 调用方不用自己先找是哪一天, 直接传整个 `trip_plan` 和 `node_id/地点名字` 就行。

这个函数目前没有被 `orchestrate()` 调用——“怎么判断用户确认了、什么时候该调 `apply_adjustment()`”这个触发逻辑还没接 (见文末“待接事项”), 2026-09-14 这次只是先把“执行”这个接口本身准备好, 方便编排 Agent 以后调用。

`check_weather()` 的行为: - 有真实预警, `needs_replan` 会不会标 `True` 取决于预警等级 (`severity`) 够不够到 `severe / extreme` (常量 `_NEEDS_REPLAN_SEVERITY`) ——**但不管等级多高都不会自动改 `trip_plan`**, 这只是给编排 Agent 一个“要不要用更紧迫的语气跟用户说”的信号, 不是执行开关 (2026-09-11 之前的版本在 `severe / extreme` 时会自动清空当天行程, 合并 `fellow` 分支时改掉了, 统一成提案制) - 没有预警返回 `has_warning: False`, 是正常情况; `weather_tool` 查询本身失败 (key 没配/地名查不到/网络问题) 不会抛异常炸穿调用方, 优雅降级返回带 `error` 字段的结果——跟 `route_agent.py` 处理 `map_tool` 查询失败是同一个思路 - `orchestrator_agent.py` 里 `exception` 意图命中时会额外跑一次: 从用户消息里提取城市 (`_KNOWN_CITIES = (“澳门”, “香港”)`), 跟 `content_agent.extract_city` 同一套子串匹配思路, 独立一份没有互相 `import`, 两个模块本来就不该耦合), 提取到了才调用 `check_weather()`, 结果挂在 `results[“exception”][“weather_check”]` 里, 最后收尾的 LLM (或 `restaurant` 命中时的字符串拼接) 会把这个提案说给用户听 - **不写 `trip_plan.weather_alerts`**: 提案制意味着“记录下来”本身也算一种执行, 所以这版故意不调 `trip_plan.add_weather_alert()` ——`GET /trip` 暂时看不到这些真实预警, 等“确认后执行”那个接口做出来了再一并把写入这一步补上

widgets.py -- 展示插件 (右侧聊天框富交互组件)

职责: 右侧聊天框里除了纯文字回复之外的富交互小组件 (帖子列表、景点勾选等), 跟 Agent/编排逻辑解耦——组件只负责“从真实候选集里挑/怎么展示”, 不重新跑检索或编内容。

设计原则: - 候选集永远来自真实代码算出来的数据 (目前是 `content_agent.run()` 的 `recommendations`, 已经是 `store.query_similar_posts()` 按人格相似度排过序的真实结果), 不允许凭空捏造。 - 要用 LLM 做“选择/排序”时, LLM 只能从候选集里选 ID, 不允许自己编内容; `_llm_select()` 会校验 LLM 返回的 ID 是否都在候选集里, 筛掉任何编造的 ID (防幻觉), LLM 调用/解析失败时优雅降级成“按候选集原有顺序截取前 N 个”, 不影响整体流程。 - 每个 widget 统一格式 `{“widget”: “<type>”, “data”: {...}}`, 前端按 `widget` 类型分发渲染, 渲染逻辑完全不用管数据是怎么算出来的。 - 模型档位: `_llm_select()` 内部用 `llm_tool.MODEL_LIGHT` (选择/排序是结构化任务, 不需要强模型)。

函数	作用
<code>build_post_list_widget(candidates, top_k=3, use_llm_rerank=False)</code>	帖子展示插件: 默认直接截取候选集前 <code>top_k</code> 个 (候选集已经是真实排序过的, 不用额外调 LLM); 传 <code>use_llm_rerank=True</code> 走 LLM 二次筛选
<code>build_attraction_picker_widget(candidates, max_select=3, pool_size=6, use_llm_rerank=True)</code>	景点选择插件: 从候选里选出 <code>pool_size</code> 个放进“可选池”返回给前端, 用户从池子里最多勾 <code>max_select</code> 个; 默认走 LLM 精选候选池 (LLM 只能选真实 ID)
<code>build_flight_picker_widget(candidates, max_select=1, pool_size=3, use_llm_rerank=True)</code>	机票选择插件: 跟 <code>build_attraction_picker_widget</code> 同一套“可选池 + 前端勾选 + 结果回传”契约, 只是机票通常只订一个, 默认 <code>max_select=1</code> ; 从 <code>candidates</code> 里只挑 <code>provider_type == “flight”</code> 的, 走 LLM 精选出 <code>pool_size</code> 个放进候选池; 筛出来是空的就返回 <code>None</code> (调用方按 <code>None</code> 跳过, 不展示空插件)
<code>build_hotel_picker_widget(candidates, max_select=1, pool_size=3, use_llm_rerank=True)</code>	酒店选择插件: 跟 <code>build_flight_picker_widget</code> 同一个模式, 只挑 <code>provider_type == “hotel”</code> 的; 同样可能返回 <code>None</code>

依赖: - `build_post_list_widget / build_attraction_picker_widget` 用 `place` 字段 (2026-09-14 起从 `post_id` 换成 `place`) 做 `_llm_select` 的 ID 校验——`content_agent.run()` 的候选自那次重构起有两种来源 (社区帖子带 `post_id`, 达人 Agent 新扩展出的高德 POI 不带), `place` 是两种来源都有的字段, 继续用 `post_id` 会导致 POI 来源的候选在 LLM 精选这一步被静默漏掉。 - `build_flight_picker_widget / build_hotel_picker_widget` 的候选 (`ota_hotel_agent.run()` 的 `candidates`) 没有独立 `id` 字段, 改用 `name` 字段当 `_llm_select` 的校验 key——跟 `place / post_id` 是同样的作用, 只是换了个字段名。

四个 widget 分两种交互模式： `post_list` 是纯展示（截取直接列出来）； `attraction_picker` / `flight_picker` / `hotel_picker` 是"可选池 + 前端勾选 + 结果回传"—— `options` + `max_select` 是统一契约，机票/酒店默认 `max_select=1`（通常只订一个），景点默认 `max_select=3`（可以多选几个）。

现状：四个 widget 都已经真正接进 `web/index.html` 渲染，`POST /widget-response` 接口也做完了（见 `server.py` 一节）——右侧聊天框里能看到真实的卡片/勾选交互，勾选点"确认选择"会真的把机票/酒店写进 `trip_plan`、把景点排进路线，不再是"传了但没人用"的状态。

待接事项： - 讨论过的其他 widget 想法还没做：反馈评分插件、异常变更确认插件、人格问卷引导插件

schedule_widgets.py -- 左侧日程面板展示组件

职责：服务对象是左侧实时日程面板（`server.py` 的 `GET /trip`，`web/index.html` 目前的文字列表），跟右侧聊天框的 `widgets.py` 是同一个"数据/展示分离"思路——这里只算"给前端画图/排版用的数据"，不产出任何 HTML/画布逻辑，真正怎么画留给前端。模型档位：不需要 LLM，纯确定性计算（按天/类型分配颜色 + 查真实地理数据）。三个 widget：

函数	作用
<code>build_trip_map_widget(trip_plan_obj, city=None)</code>	地图组件：把每天的景点/餐饮节点标进地图（同一天同一个颜色，颜色按"第几天"从固定调色板分配，超过 8 天循环复用），并把当天节点依次连成一条 真实路线 （查真实路况，不是直线连线，颜色跟当天 <code>markers</code> 一致）；机票起降机场、酒店地址也各标一个点，用固定颜色（不参与按天上色，因为它们不属于"某一天"）。多城市行程会按地理距离自动 分帧 （见下），不再是所有点挤在同一张地图里
<code>build_day_timeline_widget(trip_plan_obj)</code>	每日行程时间线：把每天的节点按时间顺序整理成竖排列表，按天分模块，模块颜色跟 <code>build_trip_map_widget</code> 里同一天的颜色对齐，方便地图和列表对照着看
<code>build_booking_panel_widget(trip_plan_obj)</code>	机票/酒店面板：原样呈现 <code>trip_plan</code> 里已经落地确认的 <code>flights</code> / <code>hotels</code> 记录——注意这跟 <code>widgets.py</code> 的 <code>build_flight_picker_widget</code> / <code>build_hotel_picker_widget</code> 不是一回事，那两个是"聊天框里给用户挑的候选推荐"，这里是"已经确认、要显示在左侧行程里的记录"

`build_trip_map_widget` 返回结构（**分帧版**，2026-09-11 起替换了原来的扁平 `markers` / `routes` 结构）：

```
{
  "widget": "trip_map",
  "data": {
    "frames": [
      {
        "frame_id": "frame-1",
        "center": { "lng": ..., "lat": ... },
        "markers": [
          {
            "day": ...,
            "color": ...,
            "place": ...,
            "node_id": ...,
            "type": "attraction|meal|airport|hotel",
            "lng": ...,
            "lat": ...
          },
          ...
        ],
        "routes": [
          {
            "day": ...,
            "color": ...,
            "coordinates": [
              [ "lng", "lat" ],
              ...
            ]
          },
          ...
        ],
        "unclustered_airports": [
          {
            "day": ...,
            "color": ...,
            "place": ...,
            "node_id": ...,
            "type": "airport",
            "role": ...,
            "flight_no": ...,
            "status": ...,
            "lng": ...,
            "lat": ...
          },
          ...
        ],
        "days_legend": [
          { "date": ..., "color": ... },
          ...
        ],
        "geocode_failures": [
          { "place": ..., "reason": ... },
          ...
        ],
        "route_failures": [
          { "day": ..., "from": ..., "to": ..., "reason": ... },
          ...
        ]
      },
      ...
    ],
    "unclustered_airports": [
      {
        "day": ...,
        "color": ...,
        "place": ...,
        "node_id": ...,
        "type": "airport",
        "role": ...,
        "flight_no": ...,
        "status": ...,
        "lng": ...,
        "lat": ...
      },
      ...
    ],
    "days_legend": [
      { "date": ..., "color": ... },
      ...
    ],
    "geocode_failures": [
      { "place": ..., "reason": ... },
      ...
    ],
    "route_failures": [
      { "day": ..., "from": ..., "to": ..., "reason": ... },
      ...
    ]
  }
}
```

- **为什么要分帧：**早期版本是所有 marker 挤进同一张地图，跨城市行程（比如"杭州玩三天+机票飞北京"）一旦机票起降机场跟行程主城市离得远，地图会被迫缩到能同时装下两座城市的比例尺，近处的景点全部挤成一个点，什么都看不清。改成按地理距离把 marker 分组，每组（帧）各自算自己的地图范围/比例尺，前端各画一个独立的 `AMap.Map` 实例，近处的点就能放大到看得清的程度
- **分帧算法**（`schedule_widgets.py` 里的 `_cluster_by_distance` + `_haversine_m`）：对当天的景点/餐饮/酒店 marker 用 `haversine` 距离做贪心单链聚类，阈值 `_FRAME_CLUSTER_THRESHOLD_M = 50_000`（50km）——两个点只要有一条 $\leq 50\text{km}$ 的链路就会被分进同一帧，超过阈值的自动分到不同帧
- **机票起降机场不参与聚类本身**，而是聚类结束、每帧的中心点算出来之后，拿机场坐标跟每一帧的中心点比距离，落在 `_AIRPORT_ATTACH_THRESHOLD_M = 80_000`（80km）以内就并入最近的那一帧（进 `frames[i].markers`），否则单独放进

- `unclustered_airports`（不画在任何一帧里，避免为了容纳一个远处的机场把某一帧的比例尺又拉爆）——这是用户明确要求的规则：“起点和终点不算，直接忽略就行”
- 景点/餐饮 `marker` 的 `day / color` 按天分配；机票（`type: "airport"`，额外带 `role: "depart"|"arrive"`、`flight_no`、`status`）和酒店（`type: "hotel"`，额外带 `name / check_in / check_out`）的 `day` 固定是 `None`，颜色分别固定为深灰蓝/棕色（`_AIRPORT_COLOR / _HOTEL_COLOR`），不占用按天调色板
 - 每帧内 `routes` 的坐标是把 `map_tool.route_between()` 返回的多段 `polyline` 展平成一条连续的 `[lng, lat]` 序列，直接给前端画线；一条路线按起点锚点归到最近的帧里；查询失败的那一段跳过并记进 `route_failures`，不影响其他天/其他段
 - **字段约定**： `flights` 的 `from_ / to`、 `hotels` 的 `address` 建议存能被地理编码识别的地名/地址（比如“杭州萧山国际机场”），不建议只存三字码（比如 `"HGH"`）——高德地理编码认不出机场三字码，会直接进 `geocode_failures`

现状：三个 widget 已经接进 `server.py` 的 `GET /trip`，`web/index.html` 用高德 JS API 真的把地图画出来了（见 `server.py` + `web/index.html` 一节）；已经用真实 `AMAP_KEY` 端到端验证过，标点/连线/机票酒店坐标都是真实经纬度。

现状/限制： - 跟 `route_agent.py` 一样依赖 `AMAP_KEY`（后端查经纬度/路线用的那个，注意不是前端画图用的 `AMAP_JS_KEY`），没配置时 `markers / routes` 会是空的、`*_failures` 里全是查询失败记录（不会导致整体报错，自测+真实端到端联调都验证过这个降级路径） - `route_agent.py` 里已经算过一次相邻站点的交通方式/耗时，这里为了拿到完整 `polyline` 又独立查了一次路线（避免“展示层”反过来依赖某个 Agent 的内部计算结果），会有一点重复的高德 API 调用，demo/比赛规模的免费额度足够用，不是问题 - `POST /widget-response` 确认机票/酒店后会真的调 `trip_plan.add_flight() / add_hotel()`，`build_booking_panel_widget` / 机票酒店 `marker` 现在跑起来是有真实数据的（端到端联调过：选中机票+酒店 → `/trip` 能看到确认记录） - **机票起降机场地理编码不传 `city`**： `build_trip_map_widget(trip_plan_obj, city=...)` 的 `city` 参数只用于景点/餐饮/酒店这些“行程主城市内”的地点，机场坐标查询故意不传 `city` ——接真实 key 测试时踩到过一坑：查“上海虹桥国际机场”时如果传了 `city="杭州"`，高德会把它强行匹配成杭州萧山机场附近的结果（两个机场坐标几乎重合），因为出发/到达机场天然可能分属两个不同城市，用行程主城市限定反而会会查错

main.py -- 入口脚本

职责：纯胶水代码，不包含任何 Agent 逻辑。`from agents.orchestrator_agent import new_shared_state, orchestrate` 之后直接 `re-export`，`server.py` 还是 `import main` 调这两个函数，完全不用改。`__main__` 里是完整的端到端 demo（推荐 → 排路线 → 异常应变 → 打印最终行程）。

store.py -- 达人社区内容 + 历史记录

职责：达人社区的图文帖子存储 + 检索（两阶段检索第一阶段：按人格向量相似度筛选），以及行程反馈历史记录。

存储技术：Chroma 向量库（`orchestrator/data/chroma/`，本地文件持久化）存帖子；JSON Lines 文件（`orchestrator/data/history.jsonl`）存历史记录；图片本地落盘（`orchestrator/data/images/<post_id>/`），帖子里只存相对路径。

函数	作用
<code>save_image(post_id, filename, image_bytes)</code>	写一张图，返回存进 <code>content["images"]</code> 的相对路径
<code>resolve_image_path(相对路径)</code>	相对路径转本地绝对路径，读图用
<code>add_post(post_id, persona_vector, content)</code>	存一条帖子。 <code>content</code> 字段见下表
<code>query_similar_posts(persona_vector, top_k=5, city=None)</code>	两阶段检索第一阶段：按人格向量相似度找候选帖子，返回时带 <code>similarity_score</code> ； <code>verified_local=True</code> 的帖子会被优先加权（见下面说明）；传了 <code>city</code> 会在 Chroma 查询阶段就用 <code>where={"city": city}</code> 精确过滤，不是“先按相似度截 <code>top_k</code> 再筛掉不 <code>match</code> 的”（那样可能筛到结果不够甚至是空的）
<code>find_posts_by_place(place)</code>	2026-09-14 新增 ：按地点名字精确匹配查帖子（Chroma metadata 过滤，不是向量相似度），给达人 Agent 的“口碑复核”用（ <code>content_agent._nearby_plan()</code> ）。找不到返回空列表，是正常情况——真实高德 POI 名字跟帖子里手的地点名字经常对不上，命中率本

函数	作用
	来就不高。每条额外带 <code>persona_vector</code> 字段（要显式 <code>include=["embeddings"]</code> 才拿得到，默认 <code>Chroma .get()</code> 不返回 <code>embedding</code> ），给口碑复核算余弦相似度用
<code>delete_post(post_id)</code>	删帖
<code>log_history(user_id, trip_id, record)</code>	追加一条行程反馈记录
<code>get_history(user_id=None)</code>	读历史记录，不传 <code>user_id</code> 读全部

`content` 字段（`add_post` 的第三个参数）：

字段	说明
<code>place / time_slot / avg_cost / rating / avoid_tips / verified_trip</code>	结构化字段，对齐 <code>agent-interfaces.md</code> 达人 Agent 输出契约
<code>caption</code>	帖子正文文字，可选
<code>images</code>	图片相对路径列表，可选，由 <code>save_image()</code> 生成
<code>tags</code>	标签列表，可选，跟 <code>images</code> 一样序列化存（ <code>tags_json</code> ），查询时还原回列表
<code>city / category / post_type / address / verified_local</code>	港澳达人数据库用的字段（见 <code>import_hk_macau_data.py</code> 一节）， <code>verified_local=True</code> 表示本地人认证来源

（`query_similar_posts()` / `find_posts_by_place()` 内部共用一个 `_restore_metadata()` 私有函数做 `images_json / tags_json` 反序列化，2026-09-14 从 `query_similar_posts()` 里抽出来的，别在新函数里再写一遍。）

"本地人认证"优先加权是怎么做的：`query_similar_posts()` 先按 `top_k * 3` 多捞一些候选（不是只捞 `top_k` 个），把 `verified_local=True` 的帖子相似度乘一个固定系数 `_VERIFIED_LOCAL_BOOST = 1.15`，再按加权后的分数重新排序截到 `top_k`。这个"先多捞再重排"是必须的——如果直接对 `Chroma` 已经按原始距离截好的 `top_k` 结果加权，加权只能在这几条里面换个顺序，换不进被漏掉的本地人帖子，加权就没意义了。

待定/限制：- 内容相关性排序（两阶段检索第二阶段）没实现，留给调用方在 `query_similar_posts()` 的候选集里自己排 - 图片存本地文件系统，部署到 `ModelScope Studio` 时要换成对象存储（OSS/CDN），`images` 字段到時候存 URL 而不是本地路径，上层调用方式不变 - `_VERIFIED_LOCAL_BOOST` 系数（1.15）是拍的，没有做过效果对比调优，觉得加权效果不明显/太强可以直接改这个常量

standardize_hk_macau_data.py + import_hk_macau_data.py -- 港澳达人数据库

背景：组员手动整理了一份港澳（澳门/香港）达人推荐/避坑数据，存在仓库根目录的 `数据库原始.xlsx` 里，来源分两种：- **本地人认证**（Excel 里的"本地人澳门"/"本地人香港" sheet）：饮食/景点/Tips 分类推荐 + 单独一张避坑表 - **小红书**（"小红书澳门"/"小红书香港" sheet）：褒贬都有的普通帖子，不算本地人认证来源

这两种来源对应 `store.py` 里新加的 `verified_local` 字段——本地人认证的帖子在检索时会被优先加权（见 `store.py` 一节），小红书来源不加权。这个字段是原始数据自带的真实来源标记（组员整理的时候已经分好表了），不是靠算法从内容"判断"出来的。

两步流程（分开是为了标准化出错时不用重新灌一次向量库）：

脚本	作用
<code>standardize_hk_macau_data.py</code>	读 <code>数据库原始.xlsx</code> ，标准化字段 + 编号，写出 <code>data_sources/hk_macau_posts.json</code> 。不碰 <code>Chroma</code>
<code>import_hk_macau_data.py</code>	读标准化 JSON，用 <code>persona.infer_post_persona_vector()</code> 给每条帖子算一个人格向量，调 <code>store.add_post()</code> 灌进 <code>Chroma</code>

编号规则（城市前缀 + 类型字母 + 三位数字，类型内连续编号，不区分本地人/小红书来源）：

	澳门·推荐	澳门·避坑	香港·推荐	香港·避坑
编号格式	MF/MS/MT + 三位数字	MN + 三位数字	HF/HS/HT + 三位数字	HN + 三位数字
示例	MF001, MS001, MT001	MN001, MN002	HF001, HS001, HT001	HN001, HN002
说明	饮食/景点/Tips, 正常分类	全部统一放这里，不分饮食/景点	同左	同左

解读：M=Macau, H=Hong Kong（城市前缀）；F=Food, S=Sight, T=Tips（推荐分类）；N=No（避坑专用，统一放一起不细分）。

原始表格解析上的坑：Excel 里不同分类小节的列不是对齐的（比如“本地人香港”的 Tips 小节没有单独的“名称”列，内容直接写在名称那一格；“本地人香港”饮食小节比“本地人澳门”多一列“推荐人”），standardize_hk_macau_data.py 按每个小节自己的表头动态取列，不能假设固定列位置——这个坑是解析的时候踩出来的，写死列位置会导致数据错位。

当前数据量（229 条，跑 python standardize_hk_macau_data.py 会打印这个分布）：

前缀	条数	前缀	条数
MF	50（本地人30+小红书20）	HF	19（本地人9+小红书10）
MS	50	HS	20
MT	50	HT	20
MN	10	HN	10

已知数据缺口：香港饮食类本地人认证只有 9 条，不是目标的 10 条——原始表格里就是这样，组员应该是漏填了一条，不是解析脚本的 bug，不影响其他数据使用。

怎么重新跑：

```
python orchestrator/standardize_hk_macau_data.py # 改了 Excel 或标准化逻辑之后跑
python orchestrator/import_hk_macau_data.py      # 改了人格反推逻辑，或者清空过 orchestrator/data/chroma 之后跑
```

import_hk_macau_data.py 用的是 upsert（store.add_post() 内部调的），同一个 id 重复导入会覆盖不会重复，可以放心重跑。

待接事项：- 避坑类帖子（MN / HN）反推出来的人格向量是中性默认值（见 persona.py 一节的已知局限），检索排名上不占优势也不吃亏，更合理的做法（不管人格匹配度、只要地点/类型对上就该出现）属于两阶段检索第二阶段，还没实现 - verified_local 优先加权的系数（1.15）没有做过 A/B 效果对比，是拍的经验值 - content_agent.py 的两阶段检索第二阶段接上之后，category（饮食/景点/Tips）字段可以用来做更精细的“用户问吃的就优先出饮食类”这种过滤，现在还没用上

trip_plan.py -- 旅游计划（行程/机票/酒店/天气异常）

职责：一次完整旅行的所有结构化信息，由多个 Agent 共同维护，最终汇总用于呈现。

顶层结构：

```
trip_plan = {
    "trip_id": "...",
    "flights": [...],          # OTA/酒店 Agent 维护
    "hotels": [...],          # OTA/酒店 Agent 维护
    "weather_alerts": [...], # 异常应变 Agent 维护
    "days": {日期: day_plan},# 行程 Agent 生成, 异常应变 Agent 增删改
}
```

景点通勤+餐饮的核心设计：每天一个“链表”，但不是指针式链表，而是**节点字典 + id 引用**（`day_plan["nodes"]` 是 `{node_id: node}`，每个节点有 `next_id` 指向下一个节点的 id，`day_plan["head_id"]` 是链表头）。这样设计是因为：- 异常应变 Agent 改行程时只需要动被影响的那一个节点、接一下前后 `next_id`，不用重发整天的数组 - 本质是个普通 dict，直接能存 JSON/传 HTTP，不需要额外的链表↔数组转换逻辑

节点字段：`type`（`"attraction" | "meal"`）、`place`、`arrival_transport`、`arrival_time`、`end_time`、`next_id`；`meal` 类型节点多一个 `meal_type`（早餐/午餐/晚餐/夜宵）。

函数	作用
<code>new_trip_plan(trip_id)</code>	造一个空旅游计划
<code>add_flight / add_hotel / add_weather_alert</code>	往对应列表追加一条记录
<code>get_or_create_day(trip_plan, date)</code>	拿到某天的 <code>day_plan</code> ，不存在就新建
<code>add_stop(day_plan, node_id, type_, place, arrival_transport, arrival_time, end_time, after_id=None, **extra)</code>	插入一个节点， <code>after_id=None</code> 插到最前面，否则插到该节点后面
<code>remove_stop(day_plan, node_id)</code>	删除节点，自动重连前后节点。低层原语，调用方要先自己找到 <code>day_plan</code>
<code>cancel_stop_by_id(trip_plan, node_id)</code>	2026-09-14 新增：按 <code>node_id</code> 删节点，不用先自己找是哪一天——遍历 <code>trip_plan["days"]</code> 定位到再删，返回被删节点内容（带 <code>date / node_id</code> ）或 <code>None</code>
<code>cancel_stops_by_place(trip_plan, place)</code>	2026-09-14 新增：按地点名字（精确匹配）删节点，可能跨天/命中多个，返回被删节点列表。这两个是 <code>remove_stop()</code> 的高层封装，给 <code>exception_agent.apply_adjustment()</code> 用，也是编排 Agent"确认后执行"时应该调的接口，不建议跳过封装直接调 <code>remove_stop()</code>
<code>patch_stop(day_plan, node_id, **fields)</code>	只改某个节点的部分字段，不动链表结构
<code>day_stops(day_plan)</code>	把链表还原成有序数组，渲染/地图面板用
<code>render(trip_plan)</code>	汇总成最终展示结构（ <code>flights / hotels / weather_alerts / days</code> ，每天的 <code>stops</code> 已经是有序数组）

现状：已经接进 `main.py` 的 `shared_state["trip_plan"]`，`route_agent` 会往里面加节点。`exception_agent` 现在是提案制，不会自己删节点——真要删得靠编排 Agent 调 `exception_agent.apply_adjustment()`（内部调 `cancel_stops_by_place()`），但这一步还没接进 `orchestrate()`（见“待接事项”）。目前所有节点都写进同一个占位日期 `"day-1"`（`main.py` 里的 `_PLACEHOLDER_DAY`），还没做真正的多日期规划。

persona.py -- 人格变量

职责：定义“旅游人格”的具体维度结构，供达人/行程/OTA Agent 读取，反馈闭环用来校准。

维度设计（量化的维度都用了 0~1 连续分数，不是纯标签）：

维度	归属	类型	说明
<code>taste</code>	<code>stable_traits</code> （跨场景稳定）	固定词表 multi-hot	菜系标签，词表见 <code>_TASTE_VOCAB</code>
<code>novelty_score</code>	<code>stable_traits</code>	float 0~1	0=稳妥大众，1=小众冒险
<code>pace_score</code>	<code>scenario_traits</code> （按场景分开存）	float 0~1	0=完全休闲，1=完全特种兵
<code>budget_score</code>	<code>scenario_traits</code>	float 0~1	0=穷游，1=公务舱/总统套房/租车这种享受型消费； 硬过滤字段，不进相似度向量 ，用

维度	归属	类型	说明
			budget_filter_ok() 按数值区间过滤
social_mode	scenario_traits	分类 (solo / couple / family / friends)	并列模式非程度光谱，向量里按 one-hot 编码
interest_theme	scenario_traits	固定词表 multi-hot	词表见 _INTEREST_VOCAB

scenario_traits 按"本次旅行模式" (business_trip / vacation / family / solo_adventure ...) 分开存，同一个人不同场景下这些值可以完全不同。

函数	作用
new_persona(user_id)	造一份空人格
bootstrap_from_onboarding(user_id, scenario, answers)	冷启动：从一份问卷答案组出初始 persona
set_scenario_traits(persona, scenario, **fields) / get_scenario_traits(persona, scenario)	读写某场景的特质，写入时会校验词表 + clamp 数值到 0~1
update_stable_traits(persona, **fields)	读写跨场景稳定特质，同样有校验
apply_feedback(persona, scenario, dimension, new_value, reason="")	按维度校准，写入 + 留痕 (feedback_log)。"该改成什么值"由调用方决定，这里只负责写入
budget_filter_ok(a_score, b_score, max_diff=0.25)	判断两个 budget_score 是否够接近，硬过滤专用，独立于相似度向量
compute_persona_vector(persona, scenario)	拼出向量：[novelty_score, taste multi-hot, pace_score, social_mode one-hot, interest_theme multi-hot]，固定 21 维 (词表大小变了维度也会变，加了"葡国菜"后从 20 变 21)
infer_post_persona_vector(scenario, tags=None, avg_cost=None, category=None)	港澳达人数据库导入专用：这些帖子是组员手动整理的真实内容，没有"发帖人自己的问卷答案"，用标签/人均/分类反推一个大致合理的人格向量，见下面单独说明
cosine_similarity(vector_a, vector_b)	2026-09-14 新增： 两个人格向量的余弦相似度 (0~1，向量分量都非负)，给达人 Agent 的"口碑复核"用——拿当前用户的人格向量跟"评价过某地点的帖子"的人格向量比对。维度对不上直接返回 0.0，不抛异常

infer_post_persona_vector() 是怎么反推的 (启发式估计，不是精确画像)： - _TAG_TO_TASTE / _TAG_TO_INTEREST 两个关键词映射表，对标签文本做子串匹配，匹配上就计入对应的 taste / interest_theme；匹配不上的标签 (比如"三代传承""400年历史"这种描述性但不构成人格维度信号的) 直接丢弃，不强行凑 - category (饮食/景点) 也会补一条弱信号：饮食→"美食探店"，景点→"人文历史" - avg_cost 线性换算成 budget_score (0~250 元映射到 0~1，250 元封顶)，换算公式很粗糙，不是精确定价模型 - 标签里出现"小众/冷门/隐世"这类词 → novelty_score 偏高 (0.75)；出现"网红/热门/必打卡" → 偏低 (0.3)；都没有就是中性 0.5 - social_mode 故意不猜——单条帖子看不出"适合独行/家庭/朋友"，留空对应 compute_persona_vector() 里那段 one-hot 全 0，这是合法的"未指定"编码 - **已知局限：**避坑 (避雷理由) 类帖子在标准化数据里没有 tags / avg_cost / category，反推出来的人格向量是中性默认值 (novelty=0.5, budget=0.5，无 taste/interest)，跟任何用户人格的相似度都不会特别高也不会特别低——这类帖子更适合"不管人格匹配度、只要地点/类型对上就该出现"，属于两阶段检索第二阶段 (内容相关性排序) 该管的事，那部分还没实现

待定/限制： - compute_persona_vector() 是数值特征拼接，不是真实语义 embedding，以后接真实 embedding 模型可以整体替换掉函数体，调用方 (store.py) 接口不用变 - 改 _TASTE_VOCAB / _INTEREST_VOCAB 词表会改变向量维度，如果本地 Chroma 已经有存量数据，改词表前要清掉 orchestrator/data/chroma 重新灌数据，不然新旧向量维度对不上 (这个坑已经踩过一次，这次加"葡国菜"也重新灌了一次数据) - 从一条用户反馈文本判断"该把哪个维度调成什么值"的算法没实现，留给编排/达人 Agent 决定

server.py + web/index.html -- 呈现层 (网页)

职责：把 `main.py` 的编排 Agent、`widgets.py`、`schedule_widgets.py` 包成 HTTP 接口 + 真实渲染，配一个两栏网页——左边实时日程（地图+每日时间线+机票酒店面板），右边聊天框（文字回复+四个插件卡片）。这是目前唯一“从对话到落地预订”整条链路能真的跑通的地方。

运行方式：

```
pip install flask python-dotenv
python orchestrator/server.py
```

然后浏览器打开 `http://127.0.0.1:5000`。地图能不能真的画出来，取决于 `.env` 里三个高德 key 有没有配全（见“环境准备”一节）；没配的话页面照样能跑，只是地图是空的、控制台会有一条警告。

会话隔离（2026-09-11 合并 fellow 分支后新增）：每个浏览器发一个 `travel_session` cookie（32 位十六进制随机值），后端靠这个 cookie 从 `session_store.py`（SQLite）读写各自独立的 `shared_state`，不再是全局共享一份——不同人/不同浏览器打开不会互相覆盖行程和对话记录，但仍然是单进程本地 demo，没有账号登录体系。

接口（都是同一个 Flask app 提供，同源不用处理 CORS）：

接口	作用
GET /	返回 <code>web/index.html</code> ，服务端会把文件里的 <code>__AMAP_JS_KEY__</code> / <code>__AMAP_JS_SECURITY_CODE__</code> 占位符换成 <code>.env</code> 里的真实值再返回（这两个 key 不写进 git 里的 html 文件，跟其他密钥一样只活在 <code>.env</code> ）
GET /session	页面刷新/重新打开时用来恢复对话历史和待处理 widgets（ <code>pending_widgets</code> ），前端 <code>restoreSession()</code> 调这个
GET /trip	返回 <code>trip_plan.render()</code> 的行程 + 额外几个字段 <code>trip_map</code> / <code>day_timeline</code> / <code>booking_panel</code> （ <code>schedule_widgets.py</code> 那三个函数的输出）
POST /chat	body 传 <code>{"message": "...}"</code> ，内部调 <code>main.orchestrate()</code> ，返回编排 Agent 的输出（ <code>chat_reply</code> / <code>community_panel</code> / <code>map_panel</code> / <code>widgets</code> / <code>restaurant_evidence</code> ）。 港澳附近游现在也走这个接口 （见 <code>agents/orchestrator_agent.py</code> 一节），不用单独的 <code>/nearby-plan</code>
POST /widget-response	body 传 <code>{"widget": "attraction_picker" "flight_picker" "hotel_picker", "selected": [...]}</code> ， <code>selected</code> 是前端从对应 widget 的 <code>options</code> 里原样拿到的候选对象。服务端会先校验这个 widget 是不是这个 session 当前真的“待处理”（ <code>pending_widgets</code> ），选中项是不是真的在候选池里、有没有超过 <code>max_select</code> 、有没有重复。景点选中后调 <code>route_agent.run()</code> （旧接口，见 <code>route_agent.py</code> 一节）排进行程；机票/酒店选中后调 <code>trip_plan.add_flight()</code> / <code>add_hotel()</code> 确认预订
POST /nearby-plan / POST /nearby-weather / GET /nearby.js	2026-09-14 起下线 （返回 501）：港澳附近游并入了达人 Agent，走 <code>POST /chat</code> 就行。这三个端点+ <code>nearby_planner.py</code> 一起被吸收删除了，端点本身保留但明确返回“已下线”，避免旧前端代码发请求后卡死等结果； <code>web/nearby.js</code> / <code>web/index.html</code> 里那套独立表单+专属地图渲染这版还没跟着改，是已知的前端配套缺口，下一步要做

前端逻辑（`web/index.html`，原生 HTML/CSS/JS + 高德地图 JS SDK，没引入前端框架）：

- 发消息 → 调 `/chat` → 显示文字回复 → 把返回的 `widgets` 数组按类型分发渲染（`post_list` 是横滑卡片；`attraction_picker` / `flight_picker` / `hotel_picker` 共用同一套“复选框 + 确认按钮”组件，`max_select` 决定最多能勾几个）→ 再调一次 `/trip` 刷新左侧日程
- 三个“选择型”widget 点“确认选择”之后：把勾中的候选对象原样 `POST /widget-response`，成功后往聊天记录里加一条系统提示（“已确认：xxx”），再刷新一次左侧日程
- 左侧地图**不再是页面加载时初始化一次的单个 `AMap.Map`**（2026-09-11 起改为分帧渲染，跟后端 `trip_map.data.frames` 的结构对应）：每次 `/trip` 刷新，`renderMap()` 先把上一轮所有帧的 `AMap.Map` 实例逐个 `destroy()`，再按 `frames` 数组动态生成对应数量的 `.map-frame` 容器（`#map-frames` 下面纵向排列，每帧一个独立的 220px 高地图 div + “第 N 组 · X 个地点”标签），`drawFrameMap()` 给每帧各自 `new` 一个 `AMap.Map` 实例、只画这一帧自己的 `markers` / `routes`，各帧自动按自己的点位置合适的缩放级别（不用整条行程的极值），互不干扰
- 景点/餐饮用 `AMap.CircleMarker` 按天上色，机票/酒店 marker 固定深灰蓝/棕色（颜色跟 `schedule_widgets.py` 里的常量对应，改了那边记得这边也要改），路线用 `AMap.Polyline` 按天上色，标记点击会弹 `AMap.InfoWindow` 显示地点名（这部分单帧内

部的画法逻辑跟改分帧之前一样，没变)

- `data.unclustered_airports` (离行程主体太远、没并进任何一帧的机场) 渲染成 `#map-frames` 下方一行文字提示 ("距离行程较远, 未画在地图上: xxx"), 不占用地图画布
- 每日行程时间线现在读 `trip.day_timeline` (带颜色) 而不是原始的 `trip.days`, 模块颜色跟地图上同一天的颜色对得上

现状/限制: - 按浏览器 session 隔离状态 (见上面"会话隔离"), 但仍是单进程本地 demo, 没有账号登录体系/多进程并发处理, 仅供本地演示, 不要直接这样部署到公网 - 已经端到端联调过完整链路: "推荐+排路线+查机票酒店"发过去 → 右侧出现 `flight_picker / hotel_picker` → 模拟前端 `POST /widget-response` 选中一个航班一个酒店 → 再查 `/trip` 能看到 `flights / hotels` 里多了确认记录 (这一步是直接打 API 验证的, 没配 `AMAP_JS_KEY` 时浏览器里的地图看不到, 但数据链路是通的) - 社区图文面板 (三面板设计里"逛社区帖子墙"那块, 跟聊天框里的 `post_list` 不是一回事) 还没做进网页 - 地图是"重新全量清空再画", 不是增量更新, 行程节点很多的时候会有一点点闪烁, demo 规模不明显

待接事项

`main.py / server.py` 已经把所有 Agent + 两套 widgets 串成一条完整链路: 跑 `python orchestrator/main.py` 能看到一次"推荐→规划路线→异常应变→重新渲染行程"的端到端流程; 跑 `python orchestrator/server.py` 打开网页, 能看到"聊天推荐→勾选景点/机票/酒店→确认→左侧地图/时间线/机票酒店面板更新"这条更完整的闭环真的在跑 (已端到端联调验证过)。还剩这几处没做, 都不阻塞基本演示:

1. `ota_hotel_agent` 还是纯占位假数据~~ 酒店这半边已解决 (2026-09-13): 接了 `hotel_tool.py` (道旅 RollingGo, 真实酒店库存/价格); 机票还是纯占位假数据, 没有真实比价来源可接 (调研过携程/去哪儿都是企业商家合作性质, 个人开发者拿不到免费 key)。道旅 RollingGo 的 Partner Center 后台其实有机票产品 (用户 2026-09-13 在自己的后台账号里确认看到过), 但当时状态是"已下线维护", 没能拿到 endpoint/文档——等它恢复了优先去接这个, 不用再重新调研数据源, 直接照 `hotel_tool.py` 的模式 (MCP JSON-RPC over HTTP, 业务数据包两层) 写一个 `flight_tool.py` 大概率能直接抄
2. `route_agent` 只写进同一个占位日期, 没有真正多日期规划~~ **已解决 (2026-09-14)**: 新增 `route_agent.schedule()`, 真正按 `time_budget_days` 新开 `day-N` 多天结构, 到达/结束时间是真推进时间游标算出来的 (不再是 "待定" 占位文字)。旧的 `run(places, ...)` 接口保留不动 (`server.py` 的 `attraction_picker` 确认流程还在用), 只写单一占位日期的行为没变, 两个接口并存
3. `exception_agent` 用整句用户消息去子串匹配地点名字, 很粗糙 (比如"西湖"两个字出现在消息里就命中), 真实版本应该先做实体识别抽出具体地点。cancel 意图 (见第11条) 也是同一套子串匹配, 有同样的粗糙问题
4. 两阶段检索第二阶段 (候选集内部按内容相关性排序) **部分有了替代方案**: `content_agent.nearby_plan()` 的"口碑复核" (真实 POI 查社区评价 + 人格向量匹配排序) 算是对"真实周边 POI 候选"做了一种内容相关性排序, 但这只覆盖 `mode="trip" / mode="nearby"` 扩展出来的 POI 候选, `mode="trip"` 最初的种子帖子 (`store.query_similar_posts()` 直接返回的那批) 依然只有人格相似度排序, 没有二次内容相关性精排, `location_hint` 对种子这部分仍然没有实际使用
5. 反馈闭环 (用户点评行程 → 校准 persona) 还没接: `store.log_history()` 记录和 `persona.apply_feedback()` 校准都写好了, 但没人在 `orchestrate()` 里调用它们
6. `map_tool.py` 目前只查"两点之间", 没做"多点最优顺序"规划——**`route_agent.schedule()` 的 `_greedy_order()` 部分缓解了这个问题** (贪心每次选离当前最近的下一个, 不是真正的最优解, 但至少不再是"按用户/LLM 给的原始顺序排"), `map_tool.py` 本身还是只有两点查询能力没变
7. 三个高德 key 已经申请配置好并真实验证过 (西湖→灵隐寺路线、机场/酒店坐标都是真实高德数据)
8. 讨论过的其他 widget 想法还没做: 反馈评分插件、异常变更确认插件、人格问卷引导插件
9. `单会话全局 state`~~ 已解决: 合并 fellow 分支后改成 `session_store.py` (按浏览器 cookie 隔离, SQLite 存档), 仍然是单进程本地 demo, 没有登录/账号体系, 但至少不同浏览器/不同人打开不会互相覆盖状态了
10. 港澳达人数据库 (229 条, 见 `standardize_hk_macau_data.py` 一节) 已经标准化+导入 Chroma, `verified_local` 优先加权、`city` 硬过滤 (`content_agent.extract_city()` 子串匹配) 都接上了并真实验证过 (问香港只出香港、问澳门只出澳门); 但避坑类帖子的人格向量是中性默认值、`category` (饮食/景点/Tips) 字段还没用来做精细过滤, 这两个属于两阶段检索第二阶段 (第4条) 的范畴
11. `exception_agent` **提案制的"确认后执行"接口还没做~~ 已解决一半 (2026-09-14)**: 新增了 cancel 意图——用户**直接下达删除指令** ("把西湖那站删了") 时, `orchestrate()` 会立刻调 `exception_agent.apply_adjustment()` 真删, 不用二次确认, 因为消息本身就是确认; 已用真实 LLM 分类 + 真删除端到端测过。但 **`exception / check_weather()` 那种"先提案、等用户对提案表态、再执行"的两轮流程还没接**——目前只解决了"用户主动要求删"这一种触发方式, 没解决"系统主动提了个建议, 用户对着建议回答'好/确认'"这种场景 (比如 `check_weather()` 查到真实预警提了建议, 用户回"好, 帮我调整", 现在没有代码能把这

- 句"好"跟"该执行哪个提案"对应起来)。真要做,方向还是 `shared_state` 里存一个 `pending_proposal` 字段记最近一次提案,下一轮识别到"确认"类意图时去执行它
12. **cancel 执行后的"要不要全部重新排"没有对应能力** (2026-09-14, 上一条的直接后续): 删除成功后会固定追问用户"是补新活动还是重新排", 如果用户选"重新排", 目前没有"清空某一天/整个行程重新规划"这个函数——`route_agent / trip_plan` 都只有"追加节点", 没有"清空重排"。用户如果真选了这个选项, 会话会正常走进下一轮 `route / content` 意图识别, 但那两个 Agent 现在的行为是往已有行程上加节点, 不是先清空再排, 效果跟用户预期的"重新排一遍"对不上
 13. **~~两套独立天气数据源~~ 已解决** (2026-09-12): `nearby_sources.weather()` 原来接的是 Open-Meteo, 现在改成统一用 `weather_tool.get_hourly_forecast()` (和风天气逐小时预报, 免费版最多查 240 小时=10 天), 跟 `exception_agent.check_weather()` 用的灾害预警接口共用同一个 key/host。 `nearby_sources.summarize_weather()` 的输入契约也跟着换了 (从 Open-Meteo 那种 `{"hourly": {"time": [...], "temperature_2m": [...], ...}}` 嵌套结构, 改成扁平的 `[{"time": ..., "temperature_c": ..., "rain_probability": ..., "condition_text": ...}]` 列表), 判断"是否有雷暴"从匹配 Open-Meteo 的数值天气码 (`weather_code >= 95`) 改成直接检查和风天气返回的 `condition_text` 里有没有"雷"字, 更直观也不用记一张码表。真实限制: 预报范围从 Open-Meteo 的 16 天缩到了 10 天, 超出范围会走"选定日期不在预报范围内"的降级提示, 不会报错崩溃
 14. **orchestrate() 没有从用户消息里提取日期给 ota_hotel_agent.run()** (2026-09-13 接入真实酒店数据后端到端测试时发现, 之前是假数据看不出这个问题): 不管用户说"9月20号"还是别的日期, `booking` 意图命中时传给 `run()` 的 `date_range` 永远是 `None`, 酒店查询永远默认"明天起 2 晚"。真实测试里 LLM 最后组句时诚实地发现了这个落差并跟用户说明 (防幻觉提示词生效了), 但功能上确实没做到"按用户说的日期查"。修法待定, 两个方向: 简单加一段日期正则/关键词提取; 或者扩展 `classify_intent` 顺带做结构化实体抽取 (日期/星级/预算这些一起解决), 需要先定思路 (`orchestrator_agent._extract_day_count()` 后来给"几天"这个更简单的场景加了正则提取, 见第2条, 但完整日期/日期区间的提取还是没做)
 15. **~~ web/nearby.js / web/index.html 没跟着达人 Agent 重构改~~ 已解决 (2026-09-15)**: 走的是上面提到的第一个方向——`web/nearby.js` 整个删掉, `web/index.html` 里的独立附近游表单 (城市/起点/日期/时长字段 + 提交按钮)、专属地图渲染代码 (`drawNearbyMap / renderNearby / restoreNearby`)、相关 CSS 全部拿掉, 左侧面板恢复成单纯的"实时日程"展示。`server.py` 的 `/nearby-plan / /nearby-weather / /nearby.js` 三个路由也从"留着但报错的 501 占位"改成彻底移除 (路由表里已不存在, 请求直接 404)。附近游现在完全走 `POST /chat` 自然语言 ("从大三巴出发逛3小时"), 排班结果写进主 `trip_plan`, `GET /trip` 自然带出来, 前端不用维护第二套请求/渲染逻辑。真实浏览器验证过页面渲染干净, `tests/test_web_sessions.py` 同步更新 (`test_nearby_endpoints_removed`, 断言 404)
 16. **~~ map_tool.route_between() 对港澳场景两个挨得很近的真实地点偶尔查询失败~~ 已解决 (2026-09-15), 顺带修了地图坐标丢失的问题**: 真实 demo 走查时发现两个相关问题——(a) 这一条记录的路线查询偶发失败; (b) `GET /trip` 的地图组件 (`schedule_widgets.build_trip_map_widget()`) 有时会把行程拆成好几张地图、点还落在离港澳很远的地方。根因是同一个: `trip_plan.add_stop()` 存节点时只存地点名字字符串, 不存坐标——虽然 `content_agent.py` 早就用 `nearby_sources.find_origin() / nearby()` 查过真实、可靠的坐标了, 但 `route_agent._place_day()` 写节点时把这些坐标扔了; 后续不管是 `route_agent._real_leg()` 算交通时间, 还是 `schedule_widgets.build_trip_map_widget()` 画地图, 都得拿地点名字重新走一次 `map_tool.route_between() / map_tool.geocode()` ——而这俩内部用的 `geocode/geo` 接口正是这个 session 已经证实对港澳不可靠的那个 (同名地点解析到千里之外)。修法: ① `route_agent._place_day()` 写节点时把 `lng / lat` 一起存进去 (`trip_plan.add_stop()` 本来就支持 `**extra` 透传, 不用改 `trip_plan.py`); ② `route_agent._real_leg() / schedule_widgets._route_leg_coords()` 坐标已知时改用 `nearby_sources.route(a, b, mode)` (早就存在但之前没人用的坐标直查接口, 直接传经纬度算路线, 不再地理编码); ③ `build_trip_map_widget()` 拼地图标记时优先用节点上存的坐标, 没有才退回按名字查。真实验证: `mode="nearby"` 排一次班, 全程零次 `map_tool.geocode()` 调用、地图只生成 1 个框、`geocode_failures / route_failures` 都是空列表。老的 `route_agent.run()` (`server.py` 的 `attraction_picker` 确认流程还在用) 当时保留了原来的按名字查询兜底行为——**但这条路径本身就是不可靠地理编码的活跃触发点, 不是"没有回归"就完事了**: 真实测试确认用户点"确认选择"之后, 地图上出现过"上海""新疆"这种离谱定位。根因是 `server.py` 的 `apply_selection()` 把选中候选压缩成只剩 `place` 字符串 (`item.get("place")`), `content_agent` 早就查好的 `lng / lat` 被丢弃, `route_agent.run()` 只能重新按名字地理编码。同一次修复 (2026-09-15 第二轮) 补上了这条路径: `apply_selection()` 改传完整候选字典, `route_agent.run()` 坐标已知时改用 `_real_leg()` (跟 `schedule()` 共用同一个坐标直查逻辑), 没坐标才退回老的按名字查——`run()` 的 `__main__` 自测块等纯字符串调用方不受影响。真实验证: 传真实候选字典, 全程零次 `map_tool.geocode()` 调用
 17. **content_agent.run() (mode="trip") 种子选择没有按地点去重** (2026-09-15 真实 demo 演示时发现): `store.query_similar_posts()` 按人格相似度取 top_k5 候选, 只过滤掉 `category=="Tips"`, 没有任何"同一地点只留一条"的约束——两条不同的社区帖子都在夸同一家店 (真实测过"叠记咖喱美食") 完全可能同时挤进种子名额, 变成同一个地方被推荐两次, LLM 组句时自己都发现了这个重复但没法从候选层面修掉。原有的 `seen_places` 去重 (`content_agent.py` 里种子扩展周边

为等同于改动前，不会更差，只是没能享受到收窄的好处；不强求每次都收窄成功，符合项目一贯“能收窄就收窄，收窄失败就老实退回”的降级哲学。

- 聊天框把编排 Agent 的 Markdown 回复当纯文本显示，## / ** / | 表格 | 这些符号原样露在外面** (2026-09-15 用户反馈)：web/index.html 的 addMessage() 一直是 `div.textContent = content`，编排 Agent 通用组句 (orchestrator_agent.py 里没命中 restaurant / cancel 时走的 LLM 自由组句分支) 经常输出结构化的 Markdown (标题/加粗/表格/列表)，用户看到的是整段带着原始符号、没有任何格式的文字。**已解决**：引入 `marked.js` (cdnjs CDN, v9.1.6, 纯前端库，不需要改后端)，addMessage() 对 `role===“assistant”` 的字符串内容改成 `marked.parse()` 转出 HTML 再塞 `innerHTML` (user / system 角色继续用 `textContent`，用户自己打的字没必要也不该被当 HTML 渲染)；sendMessage() 里单独处理 `pendingEl` 的那处直接赋值也一并改了。`marked` 没加载成功 (比如断网、CDN 被拦) 会优雅退化回纯文本，不让聊天框崩掉。配了一套 `.msg.assistant` 下的标题/表格/列表/引用样式，不是用浏览器默认样式硬堆在聊天气泡里。真实验证：用户之前反馈的那段酒店推荐 Markdown 原文重新走一遍渲染，表格/加粗/分级标题/列表全部正常显示。
- 编排 Agent 组句回复的行程跟 trip_plan 实际排定的不一样** (2026-09-15 用户反馈：文字里 Day2 的行程跟左侧面板实际排的 Day1 对不上)：orchestrate() 通用组句分支 (else 兜底那段) 把 `shared_state["trip_plan"]` 原始链表结构 (`{“head_id”:“”, “nodes”: {id: {“”, “next_id”: “”}}}`) 连同 `results.content.recommendations` 全量候选池 (真实测过 75 条，带 `community_reviews / images / tags` 等重字段) 一起塞进 context，模型很难正确按链表顺序转述每天的行程，加上候选池信息量太大，容易把“候选”和“已经排定的行程”搞混，自己把候选重新编排一遍，跟 `route_agent.schedule()` 真实排的顺序/天数对不上。**已解决**：trip_plan 改传 `trip_plan.render()` 之后的整理版 (`{“days”: [{“date”: “”, “stops”: [有序数组]}], ...}`)，recommendations 新增 `_trim_recommendations_for_reply()` 精简成只剩 `place / category / source`；system prompt 里明确加了一句“trip_plan.days 是已经真实排定的行程，必须按它如实转述，不能自己重新编排；recommendations 里没排进 trip_plan.days 的地点只能提成备选”。真实验证：重新跑一次“9.15-9.18 澳门3天”的真实请求，回复文本的三天地点/顺序/时间跟 `trip_plan.render()` 逐字对上，未排入的候选老实标成“备选地点 (还没排进行程)”。
- 排时间的触发点从“意图分类猜中了 route”改成“用户从 attraction_picker 选完确认”** (2026-09-15)：真实测试发现同一句“帮我推荐一下怎么玩”排不排班完全取决于 `classify_intent()` (一次真实 LLM 调用) 有没有把这句话分进“route”意图，同一句话不同轮次分类结果可能不一样，导致“这次有行程表、下次没有”；而且原来自动排班用的是 `content_agent` 算出来的全量候选池 (真实测过 75 条)，用户还没表达任何偏好，算法就自己把整个行程定了。**已解决**：`orchestrate()` 不再有 `content + route` 意图 → 自动排 `mode="trip"` 这条分支 (`mode="nearby"` 不受影响，“从大三巴出发逛3小时”这种直接行动请求命中就照常立刻排，它没有“先给候选、等用户挑”这一步)；`classify_intent() / _INTENT_SYSTEM_PROMPT` 里 `route` 意图整个删除 (改动后没人用了)；server.py 的 `apply_selection()` 的 `attraction_picker` 分支从老接口 `route_agent.run()` 改调真正的骨架排班 `route_agent.schedule()` (`mode="trip", time_budget_days=1`) ——用户选完确认才是第一次真正排班的时刻，且用的是用户自己选的候选，不是算法全池子自动决定的。`attraction_picker` 选择上限从 3 放宽到 6 (`widgets.py`，对齐 `_SLOT_TEMPLATE` 一天最多 6 个节点的上限)，候选池 `pool_size` 从 6 调到 10 (给用户留出真正能挑的空间)。多天行程靠多轮“推荐→选→确认”自然累积 (`schedule()` 本来就会找第一个没用过的 `day-N` 续排，不需要新状态)。老接口 `route_agent.run() / _estimate_transport()` 改完之后彻底没有调用方了，直接删除 (连同 `orchestrator_agent._extract_day_count()`，唯一调用点被删掉后也成了死代码)。真实验证：POST /widget-response 走 `attraction_picker` 确认真实候选，确认 `route_agent.schedule()` 被调用、`trip_plan` 首次被填入、零次 `map_tool.geocode()` 调用。
- 达人 Agent 新增候选分类质检，标错了顺手改数据库** (2026-09-15，用户提出)：`route_agent.candidate_role()` 靠 `category` 字段里有没有“食”/“餐”字“分餐饮/景点”，本质是信任上游数据——社区帖子的 `category` 是人工录入的，可能真的标错 (比如一家餐厅被手误标成“景点”)，标错一条就可能把餐厅排进景点槽位，绕开骨架排班“类别配比”这个结构性保证。**已解决**：`content_agent.py` 新增 `_verify_and_fix_categories()`，候选提交给编排 Agent 之前，一批候选一次性打包成一次 `MODEL_LIGHT` 调用做质检 (不是逐条调用，控制延迟)，发现标错的就地修正、带 `post_id` 的 (社区帖子来源) 顺手调新增的 `store.update_post_category()` 写回数据库——验证过 Chroma 的 `update()` 是合并式更新，只改 `category` 这一个字段，`place / caption / tags` 等其他字段原样保留，不会因为一次分类修正把整条帖子的其他数据冲掉。高德 POI 来源没有持久化数据可写，只改这次返回结果的内存字段。LLM 调用/解析失败就什么都不改，不影响 `content_agent.run()` 主流程。真实验证：229 条真实数据跑一次没有触发误报/崩溃 (这批数据本身没查出真实标错的，属于正常情况，质检逻辑本身用真实 Chroma 读写单独验证过)。
- 酒店锚点改成“多天行程末站重心” + 已订酒店的距离复核** (2026-09-15，用户提出)：第16条加的 `ota_hotel_agent._anchor_place_from_trip()` 原来只取“最早一天第一个带坐标的站”当酒店搜索锚点——多天行程时只照顾了

第一天，比如 Day3 行程跑去冰仔，酒店搜索完全没考虑到。用户指出订酒店应该看**每天最后一站**（晚上回酒店睡觉，最后一站离酒店远不远才是真正影响住宿体验的），且已经订好的酒店只要不是特别远就不用换。**已解决**：

- 新增 `_days_last_stops()`：取每天最后一个带坐标的节点（不是第一个）。
- `_anchor_place_from_trip()` 改成取**所有天数最后一站站坐标的重心（平均值）**，不再只看某一天；RollingGo 的 `place` 参数要真实地名，用离重心最近的那一站地点名字做文字检索，但坐标本身用重心点（后续合理性校验更准确地反映“整租行程”）。
- 新增 `_existing_hotel_distance_check()`：已经订好酒店（`trip_plan.hotels` 非空）时，检查现有酒店离每天最后一站够不够近（`_HOTEL_CONVENIENCE_KM=5` 公里内不用管），超出的天数只在回复文字里提醒（`result["hotel_distance_reminder"]`），**不自动重新搜索/推荐换酒店**——酒店是用户已经确认的真实决定，系统不该擅自建议换。
- `run()` 里：已经订了酒店就不再发起新的酒店搜索（`booking` 意图每次命中都重新搜一遍候选会显得像是在暗示用户换酒店，不合理），改成只做距离复核。
- **顺带修的前置缺口**：`trip_plan.add_hotel()` 存进去的酒店记录之前没存坐标（`hotel_tool.search_hotels()` 明明有 `lat / lng`，只是 `_search_real_hotels()` 构造候选字典时没往下传，`server.py` 的 `apply_selection()` 也没存）——这是这次对话反复出现的同一类“坐标算出来了但传递链路中间丢了”问题，这次一并接上（`_search_real_hotels()` 候选带上 `lng / lat`，`apply_selection()` 的 `hotel_picker` 分支存进 `trip_plan.add_hotel()`），不然“已订酒店距离复核”这个新功能根本没有坐标可用。

真实验证：两天真实行程（`content_agent.run()` + `route_agent.schedule(time_budget_days=2)`），`_anchor_place_from_trip()` 返回的坐标跟两天末站真实坐标的算术平均值完全一致；模拟一个真实离行程很远的已订酒店（冰仔坐标），确认 `run()` 没有发起新的酒店搜索（`_search_real_hotels` 断言未调用）、`hotel_distance_reminder` 正确点名了两天行程终点都偏远。

1. **候选筛选加硬性类别配额**：景点 $\geq 2 \times$ 天数、早餐 $\geq$ 天数、午晚餐 $\geq 2 \times$ 天数，早餐/午晚餐分开管理（2026-09-16，用户提出）：用户问“一开始选的时候会区分景点和美食吗”——现状只有一个软性兜底（种子里至少 1 条“景点”，剩下纯按相似度），周边真实 POI 扩展完全没有类别配额意识；用户建议加硬性配额，且要把“美食”细分成早餐/午晚餐（保证早餐/午晚餐候选池数量分别 $\geq$ 天数/ $\geq 2 \times$ 天数，才能保证 n 天不撞同一家店）。**已解决**，贯穿 `content_agent.py`（选）和 `route_agent.py`（排）两个 Agent：
 - `content_agent.py` 恢复天数提取（`_extract_day_count()`），逻辑跟上上个提交删掉的 `orchestrator_agent` 版本一样，这次只用来决定该捞多少候选，不触发自动排班；候选池扩大到按天数缩放（`min(20 \times \text{天数}, 150)`）；新增 `_pick_seeds_with_quotas()` 替换原来“至少 1 个景点”的软性兜底，按 $2 \times \text{天数} / \text{天数} / 2 \times \text{天数}$ 强制配额挑种子。
 - 新增分类质检 `_classify_categories()`（原 `_verify_and_fix_categories()` 升级，二选一“饮食/景点”改成三选一“景点/早餐/午晚餐”，社区帖子/高德 POI 都要走一遍）——**提示词踩了一个坑**：真实测过用“如果实在看不出来就保留原分类”这种宽松措辞，一批 34 条候选里 15 条会被模型偷懒原样保留成笼统的“饮食”，改成“只要不是精确的三选一标签就必须归类，餐饮类判断不出早晚就默认午晚餐”这种强制措辞后，同一批数据、以及真实 3 天行程里全部 290 条候选（243 条来自周边高德 POI 扩展）都被归类干净，零遗留。
 - `route_agent.py` 的 `_SLOT_TEMPLATE` 加早餐槽位（08:00-09:00，必选锚点），槽位标识从“attraction/meal”二选一角色改成“attraction/breakfast/lunch_dinner”三选一池子（`_pool_for_candidate()`，候选没被分类过时兜底默认归 `lunch_dinner` 不归 `breakfast`）；`_fill_day_skeleton()` / `schedule()` 相应改成管理三个候选池；`_MAX_STOPS_PER_DAY` 从 6 调到 7（6 个槽位+1 个景点加塞）。
 - **顺带解决另一个用户提出的缺口**：“传回去的数据会有推荐指数吗”——发现数据其实已经有 `similarity_score`（社区帖子）/ `persona_match_score`（周边 POI）两个打分字段，但 `route_agent.py` 从头到尾没读过。统一成 `recommendation_score` 字段，传进 `_llm_review_day()` 的复核 payload，让“删减”判断有分可依（同等情况优先拿掉分数低的）——`pick_one()` 选点本身还是按距离/时间可行性，跟“推不推荐”是两回事，不混在一起。

真实验证：真实 3 天行程（`content_agent.run(location_hint="推荐一个3天的行程")` + `route_agent.schedule(time_budget_days=3)`），290 条候选全部归类成干净的三选一标签（景点43/早餐6/午晚餐241）、全部带 `recommendation_score`；排完的 3 天共 17 站，`meal_type` 正确区分早餐/午餐/晚餐三档，**17 个地点互不重复**（`len(set(all_places)) == 17`）。

1. **新增行程偏好确认**：搜索前先问酒店/机票偏好，跟 **persona 已有维度交叉引用**（2026-09-16，用户提出）：用户希望编排 Agent 在真正调用达人 Agent 搜索之前，先确认旅行模式、酒店需求、机票倾向、旅行节奏，做到更精准推荐；并问能不能跟 `persona` 系统交叉引用。**查过 `persona.py` 确认**：四个维度里三个已经存在——“旅行节奏”= `pace_score`、“度假 vs 出差”= `scenario`、“逛吃美食 vs 景点打卡”= `interest_theme` 标签，都不需要重新问/重新存。真正没被覆盖的只有**酒店偏好**（周边图方便 vs 单独选一家好酒店当度假体验，不等于 `budget_score`）和**机票优先级**（省钱/折衷/极致体验）。**已解决**：

- 新增 `orchestrator/trip_preferences.py` : `TripPreferences` 数据类只存这两个新字段, `describe_for_persona()` 从 `persona` 读"节奏"/"模式"给调用方用, 不重复存一份 (避免同一个概念存两处、改一个忘了改另一个)。
- `orchestrator_agent.py` : `new_shared_state()` 加 `trip_preferences / pending_trip_request` (暂存"问偏好之前用户真正想说的那句话") 两个字段; `orchestrate()` 开头新增确认流程——`content` 意图命中且 `nearby` 未命中 (即 `mode="trip"` 常规推荐场景) 时, 若偏好没问完, **一次性**列出所有缺失维度的追问 (用户已用 `AskUserQuestion` 确认过一次问完不是分好几轮), 把原始请求存进 `pending_trip_request`, 短路返回; 下一轮如果 `pending_trip_request` 非空, 就把这轮消息当回答解析 (`_parse_preference_answer()`), 一次 `MODEL_LIGHT` 调用, 用户说"继续"/解析不出来的字段用默认值兜底, 不会卡住对话), 然后取出暂存的原始请求继续走正常分发。`mode="nearby"` ("从大三巴出发逛3小时") 不需要先确认, 跟它不走 `attraction_picker` 确认流程是同一个道理。
- `ota_hotel_agent.py` : `hotel_preference="度假酒店"` 时不走 `_anchor_place_from_trip()` 的锚点收窄 (用户不介意离行程远), 改成城市级搜索 + 提高星级门槛 (`_search_real_hotels()` 新增 `star_min` 参数透传给 `hotel_tool.search_hotels()`, 那边接口本来就支持, 之前没接上); `flight_priority="省钱"` 时把假机票候选按价格排序排——**如说明局限**: 机票是假数据 (`_generate_beijing_flights()`), `flight_priority` 目前只能影响候选排序, 不能真正筛选时刻/舱位。

真实验证: 真实两轮对话, 第一轮"推荐一个3天的澳门行程"触发确认 (`community_panel` 为空, `pending_trip_request` 正确存住原始请求); 第二轮"周边方便就行, 机票随便"正确解析出 `{"hotel_preference": "周边", "flight_priority": "折衷"}`, 用暂存的原始请求真正触发了搜索 (290 条候选), 回复文本里正确引用了 `persona` 的 `interest_theme / pace_score` ("自然风光、美食探店、家庭出游、节奏偏慢")。

1. **周边 POI 扩展没有筛选/截断, 候选量爆炸** (2026-09-17, 用户反馈"周边POI也太多了"): 上一条验证时"3天澳门行程"实测出了 290 条候选, 根因是 `content_agent._nearby_plan()` 对 `nearby_sources.nearby()` (AMap 同城 POI 检索, 一次能回几十条) 的结果完全不截断——`run()` 里 `mode="trip"` 场景对每个种子 (第25条硬配额下, 3 天行程最多能有 $2 \times 3 + 3 + 2 \times 3 = 15$ 个种子) 都各自调一次 `_nearby_plan()`, 汇总去重后自然是几百条量级, 两轮 `_classify_categories()` 的 LLM payload 也跟着臃肿。用户建议参考已删除的 fellow 分支 `nearby_planner.py` (`git show <deletion-commit>~1:orchestrator/nearby_planner.py` 找回来看的) ——那边的做法是先用一次 LLM 调用把候选"从资料中选出最多6个地点" (`rank_candidates()`), 再 `pool = ranked[:8]` 硬截断到 8 个, 才进贪心排线路。**已解决**: `_nearby_plan()` 新增 `limit` 参数 (默认 `_NEARBY_PER_CALL_CAP=8`, 直接对齐 fellow 分支当年截断到 8 的量), 按已有的 `persona_match_score / recommendation_score` (口碑复核算出来的排序分) 排序后截断——跟 fellow 分支的目的 (别把一次周边查询的全部结果都塞给下游), 但不需要 fellow 那一步额外的 LLM 排序调用: 那边当年没有现成的排序依据, 只能靠 LLM 挑; 现在口碑复核已经算出了结构化分数, 直接按分数截断效果等价, 还省一次 LLM 调用和一次可能的解析失败点。真实验证: 同样"我想在9.15从北京出发去澳门玩3天"的真实请求, 候选总数从 290 降到 58~66 (景点/午晚餐类别配额依然满足, 早餐类目前为 0 条——查证是社区帖子库里澳门本来就没有早餐类型的帖子, 第25条配额"尽力而为不强求"的既有降级行为, 跟这次截断改动无关, 不是新引入的回归)。