

orchestrator/ 代码说明

给第一次看这份代码的人快速建立地图用的开发文档。`main.py` 只是薄薄的入口胶水代码，真正的 5 个 Agent 各自一个文件放在 `agents/` 目录下，`persona / store / trip_plan` 三个模块已经被对应的 Agent 接起来了（具体接了什么见文末），只有 OTA/酒店 Agent 还是纯占位假数据。

设计背景/接口契约见 [agent-architecture.md](#)（为什么这么分 Agent、为什么中心化编排）和 [agent-interfaces.md](#)（字段契约、原本的 Dify 方案，后来改成直接写 Python）。

环境准备

```
pip install openai python-dotenv chromadb
```

在 `orchestrator/.env` 里写这几行（这个文件已经在 `.gitignore` 里，不会被提交）：

```
PARATERA_API_KEY=你的key
AMAP_KEY=你的高德Web服务API Key
AMAP_JS_KEY=你的高德Web端(JS API)Key
AMAP_JS_SECURITY_CODE=你的安全密钥
QWEATHER_KEY=你的和风天气API KEY
QWEATHER_API_HOST=你的和风天气专属API Host
```

高德的 key **分三样东西，缺一不可**： - `AMAP_KEY`：**Web服务** 类型，后端用（`map_tool.py` 查地理编码/路线） - `AMAP_JS_KEY`：**Web端(JS API)** 类型，前端画地图用——注意这是另一个应用/另一个 key，不能跟上面那个通用 - `AMAP_JS_SECURITY_CODE`：安全密钥，高德 JS API 2.0 版本强制要求，在申请 `AMAP_JS_KEY` 的同一个应用页面能找到都在 <https://lbs.amap.com> 控制台"创建应用"里申请（一个应用可以同时创建 Web服务 + Web端(JS API) 两个 key，安全密钥在创建 Web端(JS API) key 的时候会一起给）。个人开发者未认证 6000次/天，实名认证后 30万次/月，demo 阶段够用。

和风天气（`weather_tool.py` 用，灾害预警）去 <https://dev.qweather.com> 控制台"项目管理"申请： -

`QWEATHER_KEY`：创建凭据时选 **API KEY** 类型，不要选 JWT（JWT 要自己写签名逻辑，demo 规模没必要） -

`QWEATHER_API_HOST`：同一个项目页面上能看到，形如 `xxxxxxxxxx.re.qweatherapi.com`，**不用带** `https://` 前缀

——2023 年后注册的新账号是"一账号一专属域名", 公共的 devapi.qweather.com 对新 key 直接返回 404, 必须用这个专属域名

个人开发者免费版 1000次/天, 灾害预警接口在免费的 8 个基础接口里 (辐射/海洋/热带气旋等付费专项接口不在内, 用不上) 。

每个文件都能直接 python orchestrator/<路径>.py 单独跑 (包括 agents/ 里的 5 个文件), 文件末尾的 if __name__ == "__main__": 都是自测代码, 可以照着抄用法。

目录结构

```
orchestrator/
  llm_tool.py           # 通用 LLM 调用工具, 跟"编排"本身无关, 谁都能 import
  map_tool.py           # 通用地图工具 (高德地图 API): 地理编码 + 路径规划
  weather_tool.py       # 通用天气工具 (和风天气 API): 灾害预警查询, 给异常应变 Agent 用
  agents/
    orchestrator_agent.py # 编排 Agent: new_shared_state + classify_intent + orchestrate
    content_agent.py      # 达人/内容 Agent
    route_agent.py        # 行程/路线 Agent
    ota_hotel_agent.py    # OTA/酒店 Agent (还是纯占位)
    exception_agent.py    # 异常应变 Agent
  widgets.py            # 展示插件: 右侧聊天框里的富交互小组件, 跟 Agent 逻辑解耦
  schedule_widgets.py    # 左侧日程面板展示组件 (地图+连线、每日时间线、机票酒店面板), 跟 widgets.
  standardize_hk_macau_data.py # 把组员整理的港澳达人数据 Excel 转成标准化 JSON (见文末专门一节)
  import_hk_macau_data.py # 把标准化 JSON 灌进 Chroma (人格向量怎么算在这一步)
  data_sources/hk_macau_posts.json # 标准化后的港澳达人数据库 (229 条, 本地人认证 + 小红书两个来源)
  main.py               # 薄入口: re-export 编排 Agent 的两个函数 + __main__ 完整 demo
  store.py / trip_plan.py / persona.py # 不变
  server.py / web/      # 不变, 还是 import main, 接口不受这次拆分影响
```

拆分原则: 谁负责哪个 Agent 就改 agents/ 下自己那一个文件, 不用碰 main.py 或别人的 Agent 文件, 减少多人协作冲突。

llm_tool.py -- 通用 LLM 工具

职责: 跟"编排"这件事本身无关的基础设施, 5 个 Agent 里任何一个要调用模型都用这个, 不要各自再写一遍 client 初始化。

函数/常量	作用
call_llm(messages, model=MODEL_FULL)	统一的模型调用入口

函数/常量	作用
MODEL_FULL / MODEL_LIGHT	DeepSeek-V4-Pro / DeepSeek-V4-Flash , 两档模型对齐 agent-architecture.md 的模型档位设计

map_tool.py -- 通用地图工具（高德地图）

职责：地理编码 + 路径规划，给行程/路线 Agent 算真实的距离/耗时/路线用，跟 llm_tool.py 一样是通用基础设施。

函数	作用
geocode(address, city=None)	地名/地址转经纬度，返回 (lng, lat)
route_between(place_a, place_b, mode="walking", city=None)	算两地之间的距离/耗时/路线，mode 传 "walking" 或 "driving" , 返回 distance_m / duration_min / polyline

现状/限制： - 只做了"两点之间"的查询，还没做"多点一次性规划最优顺序"（这个高德也有专门接口，以后要优化路线顺序时再接） - route_agent.py 里用这个算相邻两站的真实交通方式/耗时（超过 2km 自动从步行切驾车），查询失败会优雅降级成"待定（地图查询失败：...）"文字，不会导致整个流程崩掉 - 到达/结束的具体钟点时间（arrival_time / end_time）还是占位——那需要"一天几点开始"+"每站玩多久"这类还没定义的调度逻辑，跟地图 API 是两回事 - 地图可视化（真的在网页上画一张地图+路线）还没做，web/index.html 目前只是文字列表展示行程，polyline 字段目前没被前端用上

weather_tool.py -- 通用天气工具（和风天气）

职责：灾害预警查询，给异常应变 Agent 判断"这个城市现在是不是真的有极端天气"用，跟 map_tool.py 一样是通用基础设施。

函数	作用
get_active_warnings(location, city=None)	查某个地名当前生效的灾害预警，返回列表，每条 {"headline", "event_type", "severity", "description", "effective_time", "expire_time"}；没有预警返回空列表（正常情况，不是错误）

- severity 取值：unknown / minor / moderate / severe / extreme，越靠后越严重——exception_agent.check_weather() 用这个字段决定要不要自动清空行程
- 接口本身按经纬度查（/weatheralert/v1/current/{lat}/{lon}），不需要先转和风天气自己的 LocationID，所以直接复用 map_tool.geocode() 拿坐标，少一次网络调用
- 和风天气新账号是"一账号一专属域名"：**2023 年后注册的 key 用公共的 devapi.qweather.com / geoapi.qweather.com 会直接 404，必须去控制台"项目管理"页面找到这个 key 专属的 API Host（形如 xxxxxxxxxxxx.re.qweatherapi.com），配进 .env 的 QWEATHER_API_HOST（见"环境准备"一节）

——这是接入过程里踩的第一个坑，实测过公共域名连 key 是否有效都判断不出来，报错也不明显（直接 404 空 body，不是 JSON 格式的错误信息）

- 2026-09-11 用真实预警数据验证过：查询当时有台风影响的海南（海口）能查到 2 条真实的雷电/大风黄色预警，字段解析正常；查没有预警的城市（香港）返回空列表，也验证过降级路径

agents/orchestrator_agent.py -- 编排 Agent

职责：星型架构的中枢。接收用户消息 → 意图识别 → 决定调用哪几个子 Agent → 汇总结果 → 生成回复。对应 [agent-interfaces.md 第三节](#) 的节点拓扑，只是从 Dify 可视化节点换成了 Python 函数。模型档位用 `MODEL_FULL`（全系统推理最重）。

函数	作用
<code>new_shared_state(user_id, scenario="vacation", onboarding_answers=None)</code>	造一份共享状态： <code>persona</code> （真用 <code>persona.py</code> 的结构，传了 <code>onboarding_answers</code> 就走冷启动）+ <code>trip_plan</code> （真用 <code>trip_plan.py</code> 的结构）
<code>classify_intent(user_message)</code>	调模型判断这轮要触发 <code>content / route / booking / exception</code> 里的哪几个
<code>orchestrate(user_message, shared_state)</code>	主流程：意图识别 → 分发调用 4 个子 Agent（子 Agent 直接改 <code>shared_state</code> 里的 <code>trip_plan</code> ，不用再手动写回）→ 生成回复，返回 <code>(output, shared_state)</code>

`orchestrate()` 返回的 `output` 里除了 `chat_reply / community_panel / map_panel`，还有一个 `widgets` 数组（见下面 `widgets.py` 一节）：`content` 意图命中时会调 `widgets.build_post_list_widget()` + `widgets.build_attraction_picker_widget()`，命中候选为空就是空数组。

agents/content_agent.py -- 达人/内容 Agent

职责：两阶段检索第一阶段。模型档位 `MODEL_FULL`（UGC 语义提炼），目前还没实际调用 LLM（纯向量检索）。

`run(shared_state, location_hint, top_k=3)`：算 `persona` 向量 → `store.query_similar_posts()` 查候选。
`location_hint` 现在有两个用途：(1) `_extract_city()` 从消息原文里子串匹配"澳门"/"香港"（词表 `_KNOWN_CITIES`），匹配上了就把 `city` 传给 `query_similar_posts()` 做硬过滤，不然"查香港"会混进澳门结果——纯人格相似度检索不区分城市，得靠这个过滤兜底；(2) 留给"内容相关性排序"（两阶段检索第二阶段）用，那部分还没实现。匹配不到已知城市（比如老的杭州 demo 数据、或者压根没提城市）就不过滤，跟以前行为一样。跟 `exception_agent.py` 的子串匹配是同一个"先跑起来，以后再换实体识别"的思路。

返回的 `recommendations` 每条现在除了原有字段，还带港澳数据库的字段：

`city / category / post_type / address / tags / verified_local`（杭州那批老 demo 数据没有这些，会是 `None` /空列表/ `False`，不影响原有字段读取）。

agents/route_agent.py -- 行程/路线 Agent

职责：把地点写进 `trip_plan` 某一天的行程节点。模型档位 `MODEL_LIGHT`，目前还没接 LLM，纯结构化写入。

`run(shared_state, places, time_budget=None, city=None)`：所有节点目前都写进同一个占位日期（`_PLACEHOLDER_DAY = "day-1"`）。`arrival_transport` 已经接了 `map_tool.py`，是相邻两站之间真实算出来的交通方式/耗时/距离（超过 2km 自动从步行切驾车）；`arrival_time / end_time` 还是占位文字“待定”（原因见 `map_tool.py` 那节）。

agents/ota_hotel_agent.py -- OTA/酒店 Agent

职责：查库存/比价。模型档位 `MODEL_LIGHT`。**还是纯占位假数据**，没有真实的比价/查库存来源可接——但字段已经补全到“用户选中后能直接落地”的程度：机票候选带 `flight_no / from_ / to / depart_time / arrive_time / status`，酒店候选带 `address / check_in / check_out`（`check_in / check_out` 会用 `date_range` 参数填，格式“开始日期~结束日期”，没传就给占位日期）。这样 `POST /widget-response`（见 `server.py` 一节）收到用户选中的候选后，能直接拿这些字段调 `trip_plan.add_flight() / add_hotel()`，不用现造字段。

`orchestrate()` 里 `booking` 意图命中时会把这里返回的 `candidates` 分别喂给 `widgets.build_flight_picker_widget() / widgets.build_hotel_picker_widget()`（按 `candidates` 里的 `provider_type` 字段分流，见下面 `widgets.py` 一节），现在假数据一条机票一条酒店都有，两个 widget 都能出内容。

agents/exception_agent.py -- 异常应变 Agent

职责：两条独立路径，都会直接改 `shared_state["trip_plan"]`。模型档位架构文档里写的是“中等模型”，目前只有 `MODEL_FULL / MODEL_LIGHT` 两档，先待定。

函数	作用
<code>run(shared_state, event_type, event_detail=None)</code>	按地点名字匹配 <code>trip_plan</code> 里的行程节点，命中就删掉并记一条天气异常。 <code>event_detail</code> 目前是纯子串匹配（整句用户消息去匹配地点名字），很粗糙，真实版本应该先做实体识别
<code>check_weather(shared_state, city)</code>	真查 <code>weather_tool.py</code> （和风天气灾害预警），不依赖用户有没有主动提到天气——只要能确定城市就查真实数据

`check_weather()` 的行为：- 有真实预警，会给每条预警都调一次 `trip_plan.add_weather_alert()`，字段是真实的（`event_type / severity / description` 直接来自和风天气，不再是 `run()` 里那种“未知”/“触发异常应变：xxx”占位文字）- 预警等级（`severity`）达到 `severe / extreme` 才自动清空当天所有行程节点——城市级预警没法像 `run()` 那样按地点名字定位到“具体是哪个景点受影响”，只能整体处理，所以严重程度门槛拉高（常量 `_AUTO_REMOVE_SEVERITY`），避免一条轻微预警就把整个行程清空；`moderate / minor` 只记录不动行程，留给用户自己

决定 - 没有预警返回 `has_warning: False` , 是正常情况; `weather_tool` 查询本身失败 (key 没配/地名查不到/网络问题) 不会抛异常炸穿调用方, 优雅降级返回带 `error` 字段的结果——跟 `route_agent.py` 处理 `map_tool` 查询失败是同一个思路 - `orchestrator_agent.py` 里 `exception` 意图命中时会额外跑一次: 从用户消息里提取城市 (跟 `content_agent._extract_city` 同一套子串匹配思路, `_KNOWN_CITIES = ("澳门", "香港")` , 独立一份没有互相 `import` , 两个模块本来就不该耦合) , 提取到了才调用 `check_weather()` , 结果挂在 `results["exception"]` [`"weather_check"`] 里 - 因为 `check_weather()` 是直接改 `shared_state["trip_plan"]` , `GET /trip` 会自动带出真实 `weather_alerts` (`trip_plan.render()` 本来就有这个字段) , 不需要改 `schedule_widgets.py` 或前端

widgets.py -- 展示插件（右侧聊天框富交互组件）

职责: 右侧聊天框里除了纯文字回复之外的富交互小组件（帖子列表、景点勾选等）, 跟 Agent/编排逻辑解耦——组件只负责"从真实候选集里挑/怎么展示", 不重新跑检索或编内容。

设计原则: - 候选集永远来自真实代码算出来的数据 (目前是 `content_agent.run()` 的 `recommendations` , 已经是 `store.query_similar_posts()` 按人格相似度排过序的真实结果) , 不允许凭空捏造。 - 要用 LLM 做"选择/排序"时, LLM 只能从候选集里选 ID, 不允许自己编内容; `_llm_select()` 会校验 LLM 返回的 ID 是否都在候选集里, 筛掉任何编造的 ID (防幻觉) , LLM 调用/解析失败时优雅降级成"按候选集原有顺序截取前 N 个" , 不影响整体流程。 - 每个 widget 统一格式 `{"widget": "<type>", "data": {...}}` , 前端按 `widget` 类型分发渲染, 渲染逻辑完全不用管数据是怎么算出来的。 - 模型档位: `_llm_select()` 内部用 `llm_tool.MODEL_LIGHT` (选择/排序是结构化任务, 不需要强模型) 。

函数	作用
<code>build_post_list_widget(candidates, top_k=3, use_llm_rerank=False)</code>	帖子展示插件: 默认直接截取候选集前 <code>top_k</code> 个 (候选集已经是真实排序过的, 不用额外调 LLM) ; 传 <code>use_llm_rerank=True</code> 走 LLM 二次筛选
<code>build_attraction_picker_widget(candidates, max_select=3, pool_size=6, use_llm_rerank=True)</code>	景点选择插件: 从候选里选出 <code>pool_size</code> 个放进"可选池"返回给前端, 用户从池子里最多勾 <code>max_select</code> 个; 默认走 LLM 精选候选池 (LLM 只能选真实 ID)
<code>build_flight_picker_widget(candidates, max_select=1, pool_size=3, use_llm_rerank=True)</code>	机票选择插件: 跟 <code>build_attraction_picker_widget</code> 同一套"可选池 + 前端勾选 + 结果回传"契约, 只是机票通常只订一个, 默认 <code>max_select=1</code> ; 从 <code>candidates</code> 里只挑 <code>provider_type == "flight"</code> 的, 走 LLM 精选出 <code>pool_size</code> 个放进候选池; 筛出来是空的就返回 <code>None</code> (调用方按 <code>None</code> 跳过, 不展示空插件)
<code>build_hotel_picker_widget(candidates, max_select=1, pool_size=3, use_llm_rerank=True)</code>	酒店选择插件: 跟 <code>build_flight_picker_widget</code> 同一个模式, 只挑 <code>provider_type == "hotel"</code> 的; 同样可能返回 <code>None</code>

依赖： - `content_agent.py` 返回的 `recommendations` 每条都带 `post_id` 字段（`store.query_similar_posts()` 本来就返回这个字段，之前 `content_agent.py` 组装返回值时漏传了，现已补上），
`build_post_list_widget / build_attraction_picker_widget` 靠这个字段做 ID 校验。 -
`build_flight_picker_widget / build_hotel_picker_widget` 的候选（`ota_hotel_agent.run()` 的 `candidates`）没有独立 id 字段，改用 `name` 字段当 `_llm_select` 的校验 key——跟 `post_id` 是同样的作用，只是换了个字段名。

四个 widget 分两种交互模式： `post_list` 是纯展示（截取直接列出来）；
`attraction_picker / flight_picker / hotel_picker` 是"可选池 + 前端勾选 + 结果回传"——`options + max_select` 是统一契约，机票/酒店默认 `max_select=1`（通常只订一个），景点默认 `max_select=3`（可以多选几个）。

现状：四个 widget 都已经真正接进 `web/index.html` 渲染，`POST /widget-response` 接口也做完了（见 `server.py` 一节）——右侧聊天框里能看到真实的卡片/勾选交互，勾选完"确认选择"会真的把机票/酒店写进 `trip_plan`、把景点排进路线，不再是"传了但没人用"的状态。

待接事项： - 讨论过的其他 widget 想法还没做：反馈评分插件、异常变更确认插件、人格问卷引导插件

schedule_widgets.py -- 左侧日程面板展示组件

职责：服务对象是左侧实时日程面板（`server.py` 的 `GET /trip`，`web/index.html` 目前的文字列表），跟右侧聊天框的 `widgets.py` 是同一个"数据/展示分离"思路——这里只算"给前端画图/排版用的数据"，不产出任何 HTML/画布编辑，真正怎么画留给前端。模型档位：不需要 LLM，纯确定性计算（按天/类型分配颜色 + 查真实地理数据）。三个 widget：

函数	作用
<code>build_trip_map_widget(trip_plan_obj, city=None)</code>	地图组件：把每天的景点/餐饮节点标进地图（同一天同一个颜色，颜色按"第几天"从固定调色板分配，超过 8 天循环复用），并把当天节点依次连成一条 真实路线 （查真实路况，不是直线连线，颜色跟当天 markers 一致）；机票起降机场、酒店地址也各标一个点，用固定颜色（不参与按天上色，因为它们不属于"某一天"）。多城市行程会按地理距离自动 分帧 （见下），不再是所有点挤在同一张地图里
<code>build_day_timeline_widget(trip_plan_obj)</code>	每日行程时间线：把每天的节点按时间顺序整理成竖排列表，按天分模块，模块颜色跟 <code>build_trip_map_widget</code> 里同一天的颜色对齐，方便地图和列表对照着看
<code>build_booking_panel_widget(trip_plan_obj)</code>	机票/酒店面板：原样呈现 <code>trip_plan</code> 里已经落地确认的 <code>flights / hotels</code> 记录——注意这跟 <code>widgets.py</code> 的 <code>build_flight_picker_widget / build_hotel_picker_widget</code> 不是一回事，那两个是"聊天框里给用户挑的候选推荐"，这里是"已经确认、要显示在左侧行程里的记录"

`build_trip_map_widget` 返回结构（分帧版，2026-09-11 起替换了原来的扁平 `markers / routes` 结构）：

```
{
  "widget": "trip_map",
  "data": {
    "frames": [
      {
        "frame_id": "frame-1",
        "center": {"lng":, "lat":},
        "markers": [{day, color, place, node_id, type, lng, lat, ...}], # type: attraction|meal|airport|
        "routes": [{"day":, "color":, "coordinates": [[lng,lat], ...]}],
        ...
      ],
      "unclustered_airports": [{day, color, place, node_id, type: "airport", role, flight_no, status, lng,
      "days_legend": [{"date":, "color":}],
      "geocode_failures": [{"place":, "reason":}],
      "route_failures": [{"day":, "from":, "to":, "reason":}],
    }
  }
}
```

- **为什么要分帧**：早期版本是所有 marker 挤进同一张地图，跨城市行程（比如“杭州玩三天+机票飞北京”）一旦机票起降机场跟行程主城市离得远，地图会被迫缩到能同时装下两座城市的比例尺，近处的景点全部挤成一个点，什么都看不清。改成按地理距离把 marker 分组，每组（帧）各自算自己的地图范围/比例尺，前端各画一个独立的 `AMap.Map` 实例，近处的点就能放大到看得清的程度
- **分帧算法**（`schedule_widgets.py` 里的 `_cluster_by_distance` + `_haversine_m`）：对当天的景点/餐饮/酒店 marker 用 haversine 距离做贪心单链聚类，阈值 `_FRAME_CLUSTER_THRESHOLD_M = 50_000`（50km）——两个点只要有一条 $\leq 50\text{km}$ 的链路就会被分进同一帧，超过阈值的自动分到不同帧
- **机票起降机场不参与聚类本身**，而是聚类结束、每帧的中心点算出来之后，拿机场坐标跟每一帧的中心点比距离，落在 `_AIRPORT_ATTACH_THRESHOLD_M = 80_000`（80km）以内就并入最近的那一帧（进 `frames[i].markers`），否则单独放进 `unclustered_airports`（不画在任何一帧里，避免为了容纳一个远处的机场把某一帧的比例尺又拉爆）——这是用户明确要求的规则：“起点和终点不算，直接忽略就行”
- 景点/餐饮 marker 的 `day / color` 按天分配；机票（`type: "airport"`，额外带 `role: "depart"|"arrive"`、`flight_no`、`status`）和酒店（`type: "hotel"`，额外带 `name / check_in / check_out`）的 `day` 固定是 `None`，颜色分别固定为深灰蓝/棕色（`_AIRPORT_COLOR / _HOTEL_COLOR`），不占用按天调色板
- 每帧内 `routes` 的坐标是把 `map_tool.route_between()` 返回的多段 `polyline` 展平成一条连续的 `[lng, lat]` 序列，直接给前端画线；一条路线按起点锚点归到最近的帧里；查询失败的那一段跳过并记进 `route_failures`，不影响其他天/其他段
- **字段约定**：`flights` 的 `from_ / to`、`hotels` 的 `address` 建议存能被地理编码识别的地名/地址（比如“杭州萧山国际机场”），不建议只存三字码（比如“HGH”）——高德地理编码认不出机场三字码，会直接进 `geocode_failures`

现状：三个 widget 已经接进 `server.py` 的 `GET /trip`，`web/index.html` 用高德 JS API 真的把地图画出来了（见 `server.py` + `web/index.html` 一节）；已经用真实 `AMAP_KEY` 端到端验证过，标点/连线/机票酒店坐标都是真实经纬度。

现状/限制：- 跟 `route_agent.py` 一样依赖 `AMAP_KEY`（后端查经纬度/路线用的那个，注意不是前端画图用的 `AMAP_JS_KEY`），没配置时 `markers / routes` 会是空的、`*_failures` 里全是查询失败记录（不会导致整体报错，自

测+真实端到端联调都验证过这个降级路径) - `route_agent.py` 里已经算过一次相邻站点的交通方式/耗时, 这里为了拿到完整 `polyline` 又独立查了一次路线 (避免"展示层"反过来依赖某个 Agent 的内部计算结果), 会有一点重复的高德 API 调用, demo/比赛规模的免费额度足够用, 不是问题 - `POST /widget-response` 确认机票/酒店后会真的调 `trip_plan.add_flight() / add_hotel()`, `build_booking_panel_widget` /机票酒店 marker 现在跑起来是有真实数据的 (端到端联调过: 选中机票+酒店 → `/trip` 能看到确认记录) - **机票起降机场地理编码不传 `city`**: `build_trip_map_widget(trip_plan_obj, city=...)` 的 `city` 参数只用于景点/餐饮/酒店这些"行程主城市内"的地点, 机场坐标查询故意不传 `city` ——接真实 key 测试时踩到过一个坑: 查"上海虹桥国际机场"时如果传了 `city="杭州"`, 高德会把它强行匹配成杭州萧山机场附近的结果 (两个机场坐标几乎重合), 因为出发/到达机场天然可能分属两个不同城市, 用行程主城市限定反而会查错

main.py -- 入口脚本

职责: 纯胶水代码, 不包含任何 Agent 逻辑。 `from agents.orchestrator_agent import new_shared_state, orchestrate` 之后直接 re-export, `server.py` 还是 `import main` 调这两个函数, 完全不用改。 `__main__` 里是完整的端到端 demo (推荐 → 排路线 → 异常应变 → 打印最终行程) 。

store.py -- 达人社区内容 + 历史记录

职责: 达人社区的图文帖子存储 + 检索 (两阶段检索第一阶段: 按人格向量相似度筛选), 以及行程反馈历史记录。

存储技术: Chroma 向量库 (`orchestrator/data/chroma/` , 本地文件持久化) 存帖子; JSON Lines 文件 (`orchestrator/data/history.jsonl`) 存历史记录; 图片本地落盘 (`orchestrator/data/images/<post_id>/`) , 帖子里只存相对路径。

函数	作用
<code>save_image(post_id, filename, image_bytes)</code>	写一张图, 返回存进 <code>content["images"]</code> 的相对路径
<code>resolve_image_path(相对路径)</code>	相对路径转本地绝对路径, 读图用
<code>add_post(post_id, persona_vector, content)</code>	存一条帖子。 <code>content</code> 字段见下表
<code>query_similar_posts(persona_vector, top_k=5, city=None)</code>	两阶段检索第一阶段: 按人格向量相似度找候选帖子, 返回时带 <code>similarity_score</code> ; <code>verified_local=True</code> 的帖子会被优先加权 (见下面说明) ; 传了 <code>city</code> 会在 Chroma 查询阶段就用 <code>where={"city": city}</code> 精确过滤, 不是"先按相似度截 <code>top_k</code> 再筛掉不match的" (那样可能筛到结果不够甚至是空的)
<code>delete_post(post_id)</code>	删帖
<code>log_history(user_id, trip_id, record)</code>	追加一条行程反馈记录

函数	作用
<code>get_history(user_id=None)</code>	读历史记录，不传 <code>user_id</code> 读全部

`content` 字段（`add_post` 的第三个参数）：

字段	说明
<code>place</code> / <code>time_slot</code> / <code>avg_cost</code> / <code>rating</code> / <code>avoid_tips</code> / <code>verified_trip</code>	结构化字段，对齐 <code>agent-interfaces.md</code> 达人 Agent 输出契约
<code>caption</code>	帖子正文文字，可选
<code>images</code>	图片相对路径列表，可选，由 <code>save_image()</code> 生成
<code>tags</code>	标签列表，可选，跟 <code>images</code> 一样序列化存（ <code>tags_json</code> ），查询时还原回列表
<code>city</code> / <code>category</code> / <code>post_type</code> / <code>address</code> / <code>verified_local</code>	港澳达人数据库用的字段（见 <code>import_hk_macau_data.py</code> 一节）， <code>verified_local=True</code> 表示本地人认证来源

"本地人认证"优先加权是怎么做的： `query_similar_posts()` 先按 `top_k * 3` 多捞一些候选（不是只捞 `top_k` 个），把 `verified_local=True` 的帖子相似度乘一个固定系数 `_VERIFIED_LOCAL_BOOST = 1.15`，再按加权后的分数重新排序截到 `top_k`。这个"先多捞再重排"是必须的——如果直接对 Chroma 已经按原始距离截好的 `top_k` 结果加权，加权只能在这几条里面换个顺序，换不进被漏掉的本地人帖子，加权就没意义了。

待定/限制： - 内容相关性排序（两阶段检索第二阶段）没实现，留给调用方在 `query_similar_posts()` 的候选集里自己排 - 图片存本地文件系统，部署到 ModelScope Studio 时要换成对象存储（OSS/CDN），`images` 字段到时候存 URL 而不是本地路径，上层调用方式不变 - `_VERIFIED_LOCAL_BOOST` 系数（1.15）是拍的，没有做过效果对比调优，觉得加权效果不明显/太强可以直接改这个常量

standardize_hk_macau_data.py + import_hk_macau_data.py -- 港澳达人数据库

背景： 组员手动整理了一份港澳（澳门/香港）达人推荐/避坑数据，存在仓库根目录的 `数据库原始.xlsx` 里，来源分两种： - **本地人认证**（Excel 里的"本地人澳门"/"本地人香港" sheet）：饮食/景点/Tips 分类推荐 + 单独一张避坑表 - **小红书**（"小红书澳门"/"小红书香港" sheet）：褒贬都有的普通帖子，不算本地人认证来源

这两种来源对应 `store.py` 里新加的 `verified_local` 字段——本地人认证的帖子在检索时会被优先加权（见 `store.py` 一节），小红书来源不加权。这个字段是原始数据自带的真实来源标记（组员整理的时候已经分好表了），不是靠算法从内容"判断"出来的。

两步流程（分开是为了标准化出错时不用重新灌一次向量库）：

脚本	作用
<code>standardize_hk_macau_data.py</code>	读 数据库原始.xlsx，标准化字段 + 编号，写出 <code>data_sources/hk_macau_posts.json</code> 。不碰 Chroma
<code>import_hk_macau_data.py</code>	读标准化 JSON，用 <code>persona.infer_post_persona_vector()</code> 给每条帖子算一个 人格向量，调 <code>store.add_post()</code> 灌进 Chroma

编号规则（城市前缀 + 类型字母 + 三位数字，类型内连续编号，不区分本地人/小红书来源）：

	澳门·推荐	澳门·避坑	香港·推荐	香港·避坑
编号格式	MF/MS/MT + 三位数字	MN + 三位数字	HF/HS/HT + 三位数字	HN + 三位数字
示例	MF001, MS001, MT001	MN001, MN002	HF001, HS001, HT001	HN001, HN002
说明	饮食/景点/Tips，正常分类	全部统一放这里，不分饮食/景点	同左	同左

解读：M=Macau，H=Hong Kong（城市前缀）；F=Food，S=Sight，T=Tips（推荐分类）；N=No（避坑专用，统一放一起不细分）。

原始表格解析上的坑：Excel 里不同分类小节的列不是对齐的（比如"本地人香港"的 Tips 小节没有单独的"名称"列，内容直接写在名称那一格；"本地人香港"饮食小节比"本地人澳门"多一列"推荐人"），`standardize_hk_macau_data.py` 按每个小节自己的表头动态取列，不能假设固定列位置——这个坑是解析的时候踩出来的，写死列位置会导致数据错位。

当前数据量（229 条，跑 `python standardize_hk_macau_data.py` 会打印这个分布）：

前缀	条数	前缀	条数
MF	50（本地人30+小红书20）	HF	19（本地人9+小红书10）
MS	50	HS	20
MT	50	HT	20
MN	10	HN	10

已知数据缺口：香港饮食类本地人认证只有 9 条，不是目标的 10 条——原始表格里就是这样，组员应该是漏填了一条，不是解析脚本的 bug，不影响其他数据使用。

怎么重新跑：

```
python orchestrator/standardize_hk_macau_data.py # 改了 Excel 或标准化逻辑之后跑
python orchestrator/import_hk_macau_data.py      # 改了人格反推逻辑，或者清空过 orchestrator/data/chroma
```

import_hk_macau_data.py 用的是 upsert (store.add_post() 内部调的) , 同一个 id 重复导入会覆盖不会重复, 可以放心重跑。

待接事项: - 避坑类帖子 (MN / HN) 反推出来的人格向量是中性默认值 (见 persona.py 一节的已知局限) , 检索排名上不占优势也不吃亏, 更合理的做法 (不管人格匹配度、只要地点/类型对上就该出现) 属于两阶段检索第二阶段, 还没实现 - verified_local 优先加权的系数 (1.15) 没有做过 A/B 效果对比, 是拍的经验值 - content_agent.py 的两阶段检索第二阶段接上之后, category (饮食/景点/Tips) 字段可以用来做更精细的"用户问吃的就优先出饮食类"这种过滤, 现在还没用上

trip_plan.py -- 旅游计划 (行程/机票/酒店/天气异常)

职责: 一次完整旅行的所有结构化信息, 由多个 Agent 共同维护, 最终汇总用于呈现。

顶层结构:

```
trip_plan = {
    "trip_id": "...",
    "flights": [...],          # OTA/酒店 Agent 维护
    "hotels": [...],          # OTA/酒店 Agent 维护
    "weather_alerts": [...], # 异常应变 Agent 维护
    "days": {日期: day_plan},# 行程 Agent 生成, 异常应变 Agent 增删改
}
```

景点通勤+餐饮的核心设计: 每天一个"链表", 但不是指针式链表, 而是**节点字典 + id 引用** (day_plan["nodes"] 是 {node_id: node} , 每个节点有 next_id 指向下一个节点的 id, day_plan["head_id"] 是链表头) 。这样设计是因为: - 异常应变 Agent 改行程时只需要动被影响的那一个节点、接一下前后 next_id , 不用重发整天的数组 - 本质是个普通 dict, 直接能存 JSON/传 HTTP, 不需要额外的链表<->数组转换逻辑

节点字段: type ("attraction" | "meal") 、 place 、 arrival_transport 、 arrival_time 、 end_time 、 next_id ; meal 类型节点多一个 meal_type (早餐/午餐/晚餐/夜宵) 。

函数	作用
new_trip_plan(trip_id)	造一个空旅游计划
add_flight / add_hotel / add_weather_alert	往对应列表追加一条记录
get_or_create_day(trip_plan, date)	拿到某天的 day_plan , 不存在就新建
add_stop(day_plan, node_id, type_, place, arrival_transport, arrival_time, end_time, after_id=None, **extra)	插入一个节点, after_id=None 插到最前面, 否则插到该节点后面

函数	作用
<code>remove_stop(day_plan, node_id)</code>	删除节点，自动重连前后节点（异常应变 Agent 常用，比如景点临时关闭）
<code>patch_stop(day_plan, node_id, **fields)</code>	只改某个节点的部分字段，不动链表结构
<code>day_stops(day_plan)</code>	把链表还原成有序数组，渲染/地图面板用
<code>render(trip_plan)</code>	汇总成最终展示结构 (flights / hotels / weather_alerts / days , 每天的 stops 已经是有序数组)

现状：已经接进 `main.py` 的 `shared_state["trip_plan"]` , `agent_route` 会往里面加节点、`agent_exception` 会删节点/记天气异常。目前所有节点都写进同一个占位日期 `"day-1"`（`main.py` 里的 `_PLACEHOLDER_DAY`），还没做多日期规划。

persona.py -- 人格变量

职责：定义"旅游人格"的具体维度结构，供达人/行程/OTA Agent 读取，反馈闭环用来校准。

维度设计（能量化的维度都用了 0~1 连续分数，不是纯标签）：

维度	归属	类型	说明
<code>taste</code>	<code>stable_traits</code> (跨场景稳定)	固定词表 multi-hot	菜系标签，词表见 <code>_TASTE_VOCAB</code>
<code>novelty_score</code>	<code>stable_traits</code>	float 0~1	0=稳妥大众，1=小众冒险
<code>pace_score</code>	<code>scenario_traits</code> (按场景分开存)	float 0~1	0=完全休闲，1=完全特种兵
<code>budget_score</code>	<code>scenario_traits</code>	float 0~1	0=穷游，1=公务舱/总统套房/租车这种享受型消费； 硬过滤字段，不进相似度向量 ，用 <code>budget_filter_ok()</code> 按数值区间过滤
<code>social_mode</code>	<code>scenario_traits</code>	分类 (<code>solo</code> / <code>couple</code> / <code>family</code> / <code>friends</code>)	并列模式非程度光谱，向量里按 one-hot 编码
<code>interest_theme</code>	<code>scenario_traits</code>	固定词表 multi-hot	词表见 <code>_INTEREST_VOCAB</code>

`scenario_traits` 按"本次旅行模式"（`business_trip` / `vacation` / `family` / `solo_adventure` ...）分开存，同一个人不同场景下这些值可以完全不同。

函数	作用
<code>new_persona(user_id)</code>	造一份空人格
<code>bootstrap_from_onboarding(user_id, scenario, answers)</code>	冷启动：从一份问卷答案组出初始 persona
<code>set_scenario_traits(persona, scenario, **fields)</code> / <code>get_scenario_traits(persona, scenario)</code>	读写某场景的特质，写入时会校验词表 + clamp 数值到 0~1
<code>update_stable_traits(persona, **fields)</code>	读写跨场景稳定特质，同样有校验
<code>apply_feedback(persona, scenario, dimension, new_value, reason="")</code>	按维度校准，写入 + 留痕（ <code>feedback_log</code> ）。"该改成什么值"由调用方决定，这里只负责写入
<code>budget_filter_ok(a_score, b_score, max_diff=0.25)</code>	判断两个 <code>budget_score</code> 是否够接近，硬过滤专用，独立于相似度向量
<code>compute_persona_vector(persona, scenario)</code>	拼出向量：[<code>novelty_score</code> , <code>taste multi-hot</code> , <code>pace_score</code> , <code>social_mode one-hot</code> , <code>interest_theme multi-hot</code>]，固定 21 维（词表大小变了维度也会变，加了"葡国菜"后从 20 变 21）
<code>infer_post_persona_vector(scenario, tags=None, avg_cost=None, category=None)</code>	港澳达人数据库导入专用：这些帖子是组员手动整理的真实内容，没有"发帖人自己的问卷答案"，用标签/人均/分类反推一个大致合理的人格向量，见下面单独说明

`infer_post_persona_vector()` 是怎么反推的（启发式估计，不是精确画像）： -

`_TAG_TO_TASTE` / `_TAG_TO_INTEREST` 两个关键词映射表，对标签文本做子串匹配，匹配上就计入对应的 `taste` / `interest_theme`；匹配不上的标签（比如"三代传承" "400年历史"这种描述性但不构成人格维度信号的）直接丢弃，不强行凑 - `category`（饮食/景点）也会补一条弱信号：饮食→"美食探店"，景点→"人文历史" - `avg_cost` 线性换算成 `budget_score`（0~250 元映射到 0~1，250 元封顶），换算公式很粗糙，不是精确定价模型 - 标签里出现"小众/冷门/隐世"这类词 → `novelty_score` 偏高（0.75）；出现"网红/热门/必打卡" → 偏低（0.3）；都没有就是中性 0.5 - `social_mode` 故意不猜——单条帖子看不出"适合独行/家庭/朋友"，留空对应 `compute_persona_vector()` 里那段 one-hot 全 0，这是合法的"未指定"编码 - **已知局限**：避坑（避雷理由）类帖子在标准化数据里没有 `tags` / `avg_cost` / `category`，反推出来的人格向量是中性默认值（`novelty=0.5`, `budget=0.5`，无 `taste/interest`），跟任何用户人格的相似度都不会特别高也不会特别低——这类帖子更适合"不管人格匹配度、只要地点/类型对上就该出现"，属于两阶段检索第二阶段（内容相关性排序）该管的事，那部分还没实现

待定/限制： - `compute_persona_vector()` 是数值特征拼接，不是真实语义 embedding，以后接真实 embedding 模型可以整体替换掉函数体，调用方（`store.py`）接口不用变 - 改 `_TASTE_VOCAB` / `_INTEREST_VOCAB` 词表会改变向量维度，如果本地 Chroma 已经有存量数据，改词表前要清掉 `orchestrator/data/chroma` 重新灌数据，不然新旧向量维度对不上（这个坑已经踩过一次，这次加"葡国菜"也重新灌了一次数据） - 从一条用户反馈文本判断"该把哪个维度调成什么值"的算法没实现，留给编排/达人 Agent 决定

server.py + web/index.html -- 呈现层（网页）

职责：把 `main.py` 的编排 Agent、`widgets.py`、`schedule_widgets.py` 包成 HTTP 接口 + 真实渲染，配一个两栏网页——左边实时日程（地图+每日时间线+机票酒店面板），右边聊天框（文字回复+四个插件卡片）。这是目前唯一"从对话到落地预订"整条链路能真的跑通的地方。

运行方式：

```
pip install flask python-dotenv
python orchestrator/server.py
```

然后浏览器打开 `http://127.0.0.1:5000`。地图能不能真的画出来，取决于 `.env` 里三个高德 key 有没有配全（见"环境准备"一节）；没配的话页面照样能跑，只是地图是空的、控制台会有一条警告。

接口（都是同一个 Flask app 提供，同源不用处理 CORS）：

接口	作用
GET /	返回 <code>web/index.html</code> ，服务端会把文件里的 <code>__AMAP_JS_KEY__</code> / <code>__AMAP_JS_SECURITY_CODE__</code> 占位符换成 <code>.env</code> 里的真实值再返回（这两个 key 不写进 git 里的 html 文件，跟其他密钥一样只活在 <code>.env</code> ）
GET /trip	返回 <code>trip_plan.render()</code> 的行程 + 额外三个字段 <code>trip_map</code> / <code>day_timeline</code> / <code>booking_panel</code> （分别是 <code>schedule_widgets.py</code> 那三个函数的输出），左侧日程面板用这个渲染
POST /chat	body 传 <code>{"message": "..."} </code> ，内部调 <code>main.orchestrate()</code> ，返回编排 Agent 的输出（ <code>chat_reply</code> / <code>community_panel</code> / <code>map_panel</code> / <code>widgets</code> ）
POST /widget-response	body 传 <code>{"widget": "attraction_picker"\ "flight_picker"\ "hotel_picker", "selected": [...]}</code> ， <code>selected</code> 是前端从对应 widget 的 <code>options</code> 里原样拿到的候选对象（不是前端自己编的字段，跟 <code>widgets.py</code> 里"LLM 只能选真实 ID"是同一个防幻觉思路）。景点选中后调 <code>route_agent.run()</code> 排进行程；机票/酒店选中后调 <code>trip_plan.add_flight()</code> / <code>add_hotel()</code> 确认预订

前端逻辑（`web/index.html`，原生 HTML/CSS/JS + 高德地图 JS SDK，没引入前端框架）：

- 发消息 → 调 `/chat` → 显示文字回复 → 把返回的 `widgets` 数组按类型分发渲染（`post_list` 是横滑卡片；`attraction_picker` / `flight_picker` / `hotel_picker` 共用同一套"复选框 + 确认按钮"组件，`max_select` 决定最多能勾几个）→ 再调一次 `/trip` 刷新左侧日程
- 三个"选择型" widget 点"确认选择"之后：把勾中的候选对象原样 `POST /widget-response`，成功后往聊天记录里加一条系统提示（"已确认：xxx"），再刷新一次左侧日程
- 左侧地图**不再是页面加载时初始化一次的单个 `AMap.Map`**（2026-09-11 起改为分帧渲染，跟后端 `trip_map.data.frames` 的结构对应）：每次 `/trip` 刷新，`renderMap()` 先把上一轮所有帧的 `AMap.Map` 实例逐个 `destroy()`，再按 `frames` 数组动态生成对应数量的 `.map-frame` 容器（`#map-frames` 下面纵向排列，每帧一个独立的 220px 高地图 div + "第 N 组 · X 个地点" 标签），`drawFrameMap()` 给每帧各自 `new` 一个 `AMap.Map` 实

例、只画这一帧自己的 `markers / routes`，各帧自动按自己的点位算合适的缩放级别（不用整条行程的极值），互不干扰

- 景点/餐饮用 `AMap.CircleMarker` 按天上色，机票/酒店 marker 固定深灰蓝/棕色（颜色跟 `schedule_widgets.py` 里的常量对应，改了那边记得这边也要改），路线用 `AMap.Polyline` 按天上色，标记点击会弹 `AMap.InfoWindow` 显示地点名（这部分单帧内部的画法逻辑跟改分帧之前一样，没变）
- `data.unclustered_airports`（离行程主体太远、没并进任何一帧的机场）渲染成 `#map-frames` 下方一行文字提示（"距离行程较远，未画在地图上：xxx"），不占用地图画布
- 每日行程时间线现在读 `trip.day_timeline`（带颜色）而不是原始的 `trip.days`，模块颜色跟地图上同一天的颜色对得上

现状/限制： - 全局只有一个进程内共享状态（`server.py` 里的 `_state`），是单会话 demo，没有登录/多用户/并发处理，仅供本地演示，不要直接这样部署到公网 - 已经端到端联调过完整链路："推荐+排路线+查机票酒店"发过去 → 右侧出现 `flight_picker / hotel_picker` → 模拟前端 `POST /widget-response` 选中一个航班一个酒店 → 再查 `/trip` 能看到 `flights / hotels` 里多了确认记录（这一步是直接打 API 验证的，没配 `AMAP_JS_KEY` 时浏览器里的地图看不到，但数据链路是通的） - 社区图文面板（三面板设计里"逛社区帖子墙"那块，跟聊天框里的 `post_list` 不是一回事）还没做进网页 - 地图是"重新全量清空再画"，不是增量更新，行程节点很多的时候会有一点点闪烁，demo 规模不明显

待接事项

`main.py / server.py` 已经把所有 Agent + 两套 widgets 串成一条完整链路：跑 `python orchestrator/main.py` 能看到一次"推荐→规划路线→异常应变→重新渲染行程"的端到端流程；跑 `python orchestrator/server.py` 打开网页，能看到"聊天推荐→勾选景点/机票/酒店→确认→左侧地图/时间线/机票酒店面板更新"这条更完整的闭环真的在跑（已端到端联调验证过）。还剩这几处没做，都不阻塞基本演示：

1. `ota_hotel_agent` 还是纯占位假数据（固定一条机票一条酒店），没有真实比价/查库存来源可接
2. `route_agent` 目前所有节点都写进同一个占位日期 `_PLACEHOLDER_DAY = "day-1"`，没有真正的多日期规划——这意味着"按天上色"这个视觉设计在真实多日行程里还体现不出来（永远只有一种颜色）；交通方式/耗时已经接了高德地图 API 真实计算，但到达/结束的具体钟点时间还是占位文字 "待定"
3. `exception_agent` 用整句用户消息去子串匹配地点名字，很粗糙（比如"西湖"两个字出现在消息里就命中），真实版本应该先做实体识别抽出具体地点
4. 两阶段检索第二阶段（候选集内部按内容相关性排序）还没实现，`content_agent` 里 `location_hint` 参数目前没用上
5. 反馈闭环（用户点评行程 → 校准 persona）还没接：`store.log_history()` 记录和 `persona.apply_feedback()` 校准都写好了，但没人能在 `orchestrate()` 里调用它们
6. `map_tool.py` 目前只查"两点之间"，没做"多点最优顺序"规划（比如给定 5 个景点，没有算出最优游览顺序，只是按用户/LLM 给的顺序排）
7. 三个高德 key 已经申请配置好并真实验证过（西湖→灵隐寺路线、机场/酒店坐标都是真实高德数据）
8. 讨论过的其他 widget 想法还没做：反馈评分插件、异常变更确认插件、人格问卷引导插件
9. 单会话全局 state（`server.py` 里的 `_state`），没有登录/多用户/并发处理，真要多人同时用需要重新设计状态管理

10. 港澳达人数据库（229 条，见 `standardize_hk_macau_data.py` 一节）已经标准化+导入 Chroma, `verified_local` 优先加权、`city` 硬过滤（`content_agent._extract_city()` 子串匹配）都接上了并真实验证过（问香港只出香港、问澳门只出澳门）；但避坑类帖子的人格向量是中性默认值、`category`（饮食/景点/Tips）字段还没用来做精细过滤，这两个属于两阶段检索第二阶段（第4条）的范畴